



Unidad Didáctica 4:

Métricas de rendimiento de los modelos de regresión

Calibración, métricas y explicabilidad de modelos de IA

ÍNDICE

Contenido

1.	INTRODUCCIÓN	4
2.	OBJETIVOS	5
2.1	OBJETIVO GENERAL	5
2.2	OBJETIVOS ESPECÍFICOS	5
3.	TEMA 1: COMPRENSIÓN DE LAS MÉTRICAS FUNDAMENTALES EN MODELOS DE REGRESIÓN	6
3.1.	INTRODUCCIÓN A LAS MÉTRICAS DE RENDIMIENTO EN REGRESIÓN	6
3.2.	INTERPRETACIÓN Y SIGNIFICADO	9
3.3.	LIMITACIONES Y CONSIDERACIONES	11
4.	TEMA 2: EVALUACIÓN Y COMPARACIÓN DE MODELOS DE REGRESIÓN	15
4.1.	UTILIZACIÓN DE MÉTRICAS PARA LA EVALUACIÓN DE MODELOS	15
4.2.	COMPARACIÓN DE MODELOS BASADA EN MÉTRICAS	16
4.3.	MEJORA DEL MODELO BASADA EN RETROALIMENTACIÓN DE MÉTRICAS	18
5.	TEMA 3: CONTEXTUALIZACIÓN PRÁCTICA DE LAS MÉTRICAS EN MODELOS DE REGRESIÓN	20
5.1.	MÉTRICAS DE RENDIMIENTO EN EL MUNDO REAL	20
5.2.	CONTEXTO DE IMPLEMENTACIONES DE ALGORITMOS EXISTENTES	21
5.3.	COMUNICACIÓN DE RESULTADOS A UN PÚBLICO AMPLIO	21
5.4.	CASOS DE USO Y ESTUDIOS DE CASO	22
6.	CONCLUSIONES	24
7.	BIBLIOGRAFÍA	25




Ilustración 1: Muestra perspectiva general de conceptos de regresión. Fuente: Propia

1. Introducción

¡Bienvenido a la asignatura Calibración, métricas y explicabilidad de modelos de IA/Módulo 4

La evaluación precisa de los modelos de regresión es un pilar fundamental en el campo del Machine Learning y en general en el mundo de la ciencia de datos. Estos modelos, diseñados para predecir valores continuos a partir de variables independientes, requieren de métricas específicas que puedan capturar la precisión y eficacia de sus predicciones. A diferencia de los modelos de clasificación, donde se categorizan las entradas, la regresión busca establecer una relación funcional entre variables, lo que implica desafíos únicos en su evaluación.



Ten en cuenta

Al evaluar modelos de regresión, un detalle crucial es que ninguna métrica de rendimiento funciona de manera aislada para proporcionar una imagen completa. Por lo tanto, una combinación equilibrada y una comprensión integral de múltiples métricas son esenciales para evaluar con precisión los modelos de regresión.

Entender las métricas de rendimiento en la regresión es crucial no sólo para determinar la mejor forma de ajustar y mejorar los modelos, sino también para comunicar efectivamente su rendimiento a las partes interesadas que no poseen un trasfondo técnico. Estas métricas ofrecen una valoración cuantitativa del nivel de error, la variabilidad y la capacidad de generalización de los modelos, tanto en contextos prácticos como teóricos.

En esta unidad, se abordarán en profundidad las métricas más relevantes para la evaluación de los modelos de regresión. Desde el Error Cuadrático Medio (MSE) hasta el Coeficiente de Determinación (R^2), cada métrica aporta una perspectiva distinta sobre cómo se desempeña un modelo, y su elección correcta es vital para una evaluación precisa y significativa.

Además, se hará énfasis en la aplicación práctica de estas métricas. Se explorarán ejemplos reales y estudios de caso que demuestren cómo las métricas de rendimiento pueden guiar en la mejora de modelos y en la toma de decisiones informadas. Esta perspectiva práctica ayudará a entender no solo el cálculo y la teoría detrás de estas métricas, sino también su relevancia y aplicación en el mundo real del análisis de datos y el modelado predictivo.

2. Objetivos

2.1 Objetivo general

- Proporcionar una comprensión integral de las métricas de rendimiento más importantes para los modelos de regresión, enfatizando su aplicación práctica y relevancia en la validación de modelos predictivos en el Machine Learning.

2.2 Objetivos específicos

En esta unidad se establecen tres objetivos específicos:

- Comprender las Métricas Fundamentales: Familiarizar a los científicos de datos con las métricas clave de rendimiento en regresión, como el MSE, MAE, y R^2 , etc explicando su significado, interpretación y aplicación.
- Evaluación y Comparación de Modelos: Capacitar a los científicos de datos para utilizar estas métricas en la evaluación efectiva y la comparación de diferentes modelos de regresión, fomentando la selección del modelo más adecuado para un problema dado.
- Contextualización Práctica: Enfatizar la importancia de estas métricas en contextos del mundo real, ilustrando cómo pueden influir en la toma de decisiones y en la comunicación de los resultados del modelo a un público más amplio, incluyendo stakeholders no técnicos.

3. Tema 1: Comprensión de las Métricas Fundamentales en Modelos de Regresión

3.1. Introducción a las Métricas de rendimiento en Regresión

En el ámbito del Machine Learning, las métricas de regresión son herramientas estadísticas utilizadas para evaluar y cuantificar el rendimiento de los modelos predictivos que se enfocan en pronosticar valores continuos. Estas métricas son cruciales porque ofrecen una medida objetiva del grado en que las predicciones del modelo se alinean con los valores reales. En la regresión, donde el objetivo es predecir una cantidad numérica, como el precio de una casa o la temperatura de un día, la precisión de estas predicciones es fundamental. Una métrica de rendimiento efectiva permite a los científicos de datos y analistas no solo evaluar la calidad del modelo, sino también identificar áreas de mejora y tomar decisiones informadas sobre cómo optimizar los algoritmos.

Las métricas de regresión difieren significativamente de las métricas utilizadas en otros tipos de problemas de Machine Learning, como la clasificación. Mientras que las métricas de clasificación, como la precisión o el recall, se centran en evaluar la exactitud de las etiquetas categóricas asignadas, las métricas de regresión se enfocan en cuantificar el error numérico entre las predicciones y los valores reales.

En muchas lecturas esos errores, lo encontrareis formalmente hablando como “residuos”. Esta distinción es esencial para comprender, ya que un modelo de regresión bien evaluado se basa en cuán cerca están sus predicciones de los valores reales, considerando aspectos como la magnitud del error y la variabilidad de los datos. Comprender esta diferencia es clave para aplicar el enfoque correcto y las herramientas adecuadas para medir y mejorar el rendimiento de los modelos en proyectos específicos de análisis de datos.

La evaluación efectiva de los modelos de regresión requiere una comprensión profunda de métricas específicas, cada una ofreciendo perspectivas únicas sobre el rendimiento del modelo. Por ejemplo, el Error Cuadrático Medio (MSE) y el Error Absoluto Medio (MAE) proporcionan medidas directas de la discrepancia entre los valores predichos y los reales, pero difieren en cómo tratan los valores atípicos y la magnitud del error. A continuación, en la siguiente sección, veremos el detalle de las principales métricas

Por otro lado, debemos tener en cuenta que cuando se trabaja con un modelo regresión supervisado, es importante considerar tanto la correlación entre variables como la relación de las variables dependientes con la variable independiente que desea predecir. Por lo tanto, antes de introducirnos en el mundo de las métricas, vamos a hacer hincapié en tres aspectos importantes en los problemas de regresión:

1. Correlación entre variables

La selección de las variables es el proceso de elegir qué variables o características a usar en el modelo. Las características altamente correlacionadas proporcionan información redundante ([Multicolinealidad](#)) que afectan negativamente la interpretación del modelo de regresión, evitando el sobreajuste (Overfitting) y por ende mejorando la capacidad del modelo para generalizar.

Existen librerías de python open source como **matplotlib** o **seaborn** que nos permite realizar este tipo de gráficos de una forma muy sencilla. Ejemplo de abajo de la Ilustración 2 donde podemos ver la correlación de cada una de las variables con el resto, según la intensidad de colores



Ilustración 2. Ejemplo de cálculo de matriz de correlaciones entre variables. Fuente: [Web](#)

2. Correlación de variables dependientes con la variable a predecir (target)

También es muy importante calcular la correlación entre las variables dependientes por separado y la variable independiente que deseas predecir. Esto nos dará una idea de cuan de fuerte están relacionadas. La idea es poder incluir en el modelo las variables dependientes que tiene correlación significativa con la variable a predecir y como mencionamos en el punto anterior no estén correlacionadas entre sí.




Ilustración 3. Ejemplo de cálculo de matriz de correlaciones de cada variable con la target. Fuente: [Web](#)

3. Puntos relevantes durante la creación de modelo de regresión

Partiendo de la base de que no hay solución universal para el uso de métricas y modelos de regresión en la búsqueda de una solución a un problema, a continuación, veremos una lista de aspectos para tener en cuenta cuando estamos trabajando con modelos de regresión y sus métricas. Ciertamente que algunos de éstos podrán ser válidos para el modelo de clasificación que veremos en la próxima unidad didáctica:

- **Uso de los errores de Regresión:** Utiliza métricas como el MSE, RMSE, MAE y R^2 para evaluar la calidad del modelo. Elige las métricas que sean más apropiadas para tu problema y objetivos.
- **Validación Cruzada:** Aplica la validación cruzada para evaluar el rendimiento del modelo en diferentes conjuntos de datos. Esto te ayudará a identificar el sobreajuste o subajuste.

- **Ajuste de Hiperparámetros del algoritmo usado:** Si estás utilizando algoritmos que requieren ajuste de hiperparámetros, utiliza métricas como la validación cruzada para encontrar la combinación óptima de parámetros.
- **Interpretación de Coeficientes:** Comprende la interpretación de los coeficientes del modelo. Esto te permitirá explicar cómo cada variable afecta a la variable objetivo.
- **Regularización:** Considera técnicas de regularización como la regresión Ridge o Lasso para controlar la complejidad del modelo y evitar el sobreajuste.
- **Selección de Características:** Si tienes muchas variables, utiliza métodos de selección de características para identificar las más importantes, teniendo en cuenta el término de correlación entre variables y la variable a predecir
- **Validación Externa:** Si es posible, valida el modelo en datos externos para asegurarte de que sea generalizable.



Ten en cuenta

Cualquier decisión sobre los datos o insight o pregunta sobre los datos, que un científico de datos vaya observando, siempre tiene que ser consensuada con el negocio. Recordemos que inicialmente el negocio tiene un problema y los científicos de datos estamos ahí para ayudarles a sus tomas de decisiones en su día a día.

3.2. Interpretación y Significado

En el análisis de regresión, es esencial comprender cómo medir el rendimiento y la precisión de los modelos. Cada una de estas métricas existentes ofrece una perspectiva única sobre los errores del modelo y su capacidad para capturar la variabilidad de los datos. Su correcta interpretación y aplicación son cruciales para la selección y ajuste de modelos, permitiendo a los científicos de datos tomar decisiones informadas basadas en resultados cuantitativos.

Aunque en la parte de la bibliografía podremos tener enlaces donde ver muchas métricas de rendimiento de la regresión, en la unidad veremos y profundizaremos en las más conocidas en el uso de la mayoría de los casos de uso. A continuación, mostramos en la siguiente tabla la definición y fórmulas de las principales:

	Definición	Fórmula
Error Cuadrático Medio (MSE)	Es el promedio de los cuadrados de la diferencia entre los valores predichos y reales	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
Error Cuadrático Medio (RMSE):	Es la raíz cuadra de MSE y ofrece una medida de la magnitud del error en las mismas unidades de la variable dependiente	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
Error Absoluto Medio (MAE)	Es el promedio de las magnitudes absolutas de la diferencia entre los valores predicho y los reales	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $
Coeficiente de m (R^2)	Indica la proporción de varianza en la variable dependiente que es predecible a parte de las variables independientes	$R^2 = \frac{\sum_{t=1}^T (\hat{Y}_t - \bar{Y})^2}{\sum_{t=1}^T (Y_t - \bar{Y})^2}$
Coeficiente de Determinación ajustado ($R - ajustado^2$)	Similar al R^2 pero penaliza la inclusión de variable irrelevantes (Enlace fórmula)	$R_a^2 = 1 - \left[\left(\frac{n-1}{n-k-1} \right) * (1 - R^2) \right]$
MBE (Error Sesgo Medio)	Cuantifica la diferencia promedio entre las predicciones de un modelo y los valores reales	$\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)$
RAE (Error Absoluto Relativo)	Evalúa la precisión relativa de un modelo de regresión al comparar la magnitud de los errores con respecto a la magnitud de los valores reales.	$\frac{\sum_{i=1}^n y_i - \hat{y}_i }{\sum_{i=1}^n y_i - \bar{y} }$
MAPE==MAPD (Error Porcentual Absoluto medio)	Evalúa el error porcentual promedio entre las predicciones y los valores reales.	$\frac{1}{n} \sum_{i=1}^n \frac{ y_i - \hat{y}_i }{y_i} \cdot 100\%$
NRMSE (Error cuadrático medio normalizado)	Mide la calidad de las predicciones de un modelo en relación con la variabilidad de los valores reales.	$\frac{RMSE}{Max(Y) - Min(Y)}$

RRMSE (Error cuadrático medio relativo)	Mide la precisión del modelo predictivo en relación con el rango de variables objetivo. Normaliza el RMSE según el rango de variable objetivo y lo presenta como porcentaje para facilitar comparación entre conjuntos de datos	$\frac{RMSE}{Y} \times 100$
RMSLE (Error logarítmico cuadrático medio)	Mide la precisión del modelo predictivo y es comúnmente utilizado cuando las variables tienen una amplia gama de valores y se desea penalizar los errores en una escala logarítmica	$\sqrt{(\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$

Tabla 1. Definición y fórmula de las principales métricas de regresión. Fuente: Elaboración propia.

3.3. Limitaciones y Consideraciones

En el campo de la ciencia de datos y el análisis de regresión, es crucial no sólo entender cómo se calculan y aplican diversas métricas de rendimiento, sino también ser conscientes de sus limitaciones y consideraciones especiales. Cada métrica, ya sea MSE, RMSE, MAE, R², etc tiene sus propias fortalezas y debilidades, y su elección y aplicación deben alinearse con los objetivos específicos y las peculiaridades de cada conjunto de datos. Comprender estas limitaciones no solo mejora la interpretación de los resultados y la selección de modelos, sino que también previene conclusiones erróneas y el uso inapropiado de las métricas.

Las métricas de rendimiento son herramientas fundamentales en la caja de herramientas de un científico de datos, pero como cualquier herramienta, deben ser utilizadas con conocimiento y precaución. La sensibilidad a outliers, la interpretación en el contexto de los datos, la relevancia en diferentes escenarios de modelado y las posibles distorsiones en los resultados son aspectos clave que deben ser cuidadosamente considerados. En los siguientes párrafos, explicaremos estas dimensiones críticas para cada métrica seleccionada, proporcionando una visión equilibrada y detallada que es esencial para el análisis de regresión efectivo y responsable.

	Limitaciones y Consideraciones
Error Cuadrático Medio (MSE)	Sensible a outliers debido a que eleva al cuadrado los errores, lo que puede llevar a sobreestimación del mal rendimiento en presencia de valores atípicos. Difícil de interpretar directamente en las unidades de la variable interés debido a sus unidades cuadráticas y posible comparación con otras métricas Puede ser buena métrica si no aparecen outliers en algoritmos relacionados con el gradiente, ya que nos proporciona un mínimo global

Error Cuadrático Medio (RMSE):	Es fácil de entender y computacionalmente simple y fácilmente diferenciable. Mantiene la sensibilidad de outliers del MSE, aunque se proporcione a escala directamente interpretable en términos de variable objetivo Valores bajos indican una mayor precisión predictiva Puede resultar en una sobreestimación de los grandes errores, lo que puede ser problemático en algunos contextos.
Error Absoluto Medio (MAE)	Proporciona una medida robusta frente a outliers, pero puede subestimar el impacto de errores grandes, ya que trata todos los errores por igual. Puede presentar desafíos en algoritmos basados en gradientes debido a que derivada no es continua. MAE bajo indica mejor rendimiento del modelo
Coefficiente de Determinación (R^2)	No garantiza la adecuación del modelo, un coeficiente alto no implica que necesariamente el modelo sea mejor o esté libre de problema de multicolinealidad Puede introducir sobreajuste, ya que siempre aumenta con la adición de más variables, independiente de su relevancia Es interesante hacer un estudio de los residuos para complementar esta métrica
Coefficiente de Determinación ajustado ($R - \text{ajustado}^2$)	Es fácil de interpretar, cuanto más cercano a 1, mejor es la capacidad del modelo para aplicar la variabilidad Es sensible al aumento de predictores al modelo, pero no garantiza que un alto valor sea un modelo adecuado, hay que complementarlo con otras métricas Es interesante hacer un estudio de los residuos para complementar esta métrica
MBE (Error sesgo Riesgo)	Es buena medida si desea verificar la dirección de modelo y poder rectificar el sesgo. Sesgo positivo implicaría un error sobreestimado, mientras que sesgo negativo implicaría un error subestimado. Te puede dar pistas sobre el sesgo No es una buena medida en términos de magnitud, puesto que los errores tienden a compensarse entre sí. No termina de ser muy confiable porque a veces los errores individuales elevados producen MBE bajo

RAE (Error Absoluto Relativo)	Es útil para comprender la precisión relativa Un RAE bajo indica un mejor rendimiento del modelo en términos de precisión relativa. Se expresa como valor porcentual, ejemplo: RAE=10% significa que en promedio las predicciones del modelo tienen un error del 10% en relación con los valores reales. Tomar con precaución en su uso en situaciones donde los valores reales son cercanos a cero o se necesite una métrica invariante de escala
MAPE=MAPD (Error Porcentual Absoluto medio)	Es útil para hacer fácil el entendimiento y comunicación del error porcentual en problemas donde los términos porcentajes son importantes como es el caso de predecir la demanda de productos para evitar exceso o falta de existencias El MAPE del 10% indica que, en promedio, el pronóstico fue un 10% superior a las ventas reales Puede tener limitaciones cuando se trata de valores cercanos a cero o cuando los valores reales son cero
NRMSE (Error cuadrático medio normalizado)	Hay versiones sobre esta, según lo incluido en el denominador (media, desviación, etc) pero la más utilizada es la resta máximo - mínimo La principal diferencia con RMSE es que éste normaliza RSME dividiéndolo por el rango de valores reales, lo que hace independiente de la escala de los datos y permite comparaciones más precisas entre diferentes conjuntos de datos. Con un menor NRMSE mejor será el ajuste del modelo
RRMSE (Error cuadrático medio relativo)	Permite expresar el error como un porcentaje y representa la proporción de error en relación con la media de los valores reales. Es relevante cuando se trabaja con conjunto de datos que tienen valores en diferentes escalas, ya que normaliza el error en función de la variabilidad de los valores reales. Con un menor RRMSE mejor será el ajuste del modelo

RMSLE (Error logarítmico cuadrático medio)	Es resistente a valores atípicos donde los errores pequeños y grandes se tratan de manera uniforme. Adecuado en distribuciones asimétricas o sesgadas. No es apropiado si se trabaja con valores negativos. Con un menor RMSLE mejor será el ajuste del modelo Puede resultar útil en situaciones en las que no nos molesta la sobreestimación, pero la subestimación no es aceptable. Aplicación: El RMSLE es especialmente útil cuando se trabaja con datos donde las diferencias relativas son más importantes que las diferencias absolutas. Por ejemplo, en problemas de predicción de precios de viviendas, una diferencia de \$100,000 en un precio alto puede ser menos significativa que una diferencia de \$10,000 en un precio bajo.
--	---

Tabla 2. Principales limitaciones y consideración de métricas de regresión Fuente: Elaboración propia.



Ten en cuenta

Es importante recordar que la elección de la métrica adecuada debe basarse en el contexto específico del análisis y los datos disponibles.



Material de ampliación

[Libro estadístico](#), donde se puede profundizar en muchos aspectos de sobre la regresión y su contexto:

4. Tema 2: Evaluación y Comparación de Modelos de Regresión

La evaluación y comparación de modelos son procesos cruciales en el campo de la ciencia de datos y el aprendizaje automático. Estos pasos no solo determinan la eficacia de un modelo en particular para una tarea dada, sino que también proporcionan insights valiosos sobre cómo diferentes modelos se comportan en distintos conjuntos de datos y bajo variadas condiciones.

Al comparar modelos, los científicos de datos pueden discernir cuál es más adecuado para responder a preguntas específicas o para resolver problemas particulares. Este proceso implica no solo mirar el rendimiento de un modelo en términos de precisión y error, sino también considerar aspectos como la complejidad del modelo, la generalización a nuevos datos y la interpretabilidad de los resultados.

Además, la evaluación y comparación de modelos no se limita a una sola métrica o criterio. Este enfoque multifacético es esencial para evitar conclusiones erróneas que podrían surgir al depender de una sola métrica. En este contexto, la habilidad para aplicar adecuadamente estas métricas y entender sus resultados es fundamental para cualquier científico de datos. Este módulo se enfocará en desarrollar estas habilidades, proporcionando las herramientas necesarias para evaluar críticamente y comparar eficazmente diferentes modelos de regresión, lo que es vital para la selección y optimización de modelos en la práctica de la ciencia de datos.

4.1. Utilización de Métricas para la Evaluación de Modelos

Las métricas de rendimiento como MSE, RMSE, MAE y R^2 , etc como las vistas anteriormente son fundamentales en la ciencia de datos para evaluar la precisión y la eficacia de los modelos de regresión. Cada una de estas métricas ofrece perspectivas únicas sobre diferentes aspectos del rendimiento del modelo, desde la magnitud de los errores hasta la proporción de la varianza explicada. Este conocimiento no solo es crucial para afinar modelos existentes, sino también para seleccionar el modelo más adecuado para un conjunto de datos y una tarea específica.

Ejemplo las métricas MSE y el RMSE son particularmente útiles en contextos donde los errores grandes son más críticos. Por ejemplo, en la modelación financiera, un alto error en las predicciones puede tener implicaciones significativas en términos de costos o inversiones. Por otro lado, el MAE ofrece un enfoque más equilibrado, tratando todos los errores por igual, lo que lo hace ideal en situaciones donde cada error, independientemente de su tamaño, es igualmente importante, como en sistemas de recomendación. El R^2 es invaluable para medir qué tan bien las variables independientes explican la variabilidad en la variable dependiente, como en los estudios de investigación que exploran relaciones entre variables, éste siempre suele ir acompañado de un estudio de los residuos (diferencia valores reales menos valores predichos).

Al comparar modelos, es crucial seleccionar la métrica más apropiada para el problema en cuestión. Por ejemplo, en un modelo de pronóstico del tiempo, un bajo RMSE indicaría predicciones de temperatura muy precisas, mientras que un alto R^2 en un estudio económico podría mostrar una fuerte correlación entre las características del mercado y las tendencias de consumo. Estos ejemplos demuestran cómo diferentes métricas pueden ofrecer distintas perspectivas sobre el rendimiento de un modelo, y por qué es importante considerar múltiples métricas al evaluar y comparar modelos.

En resumen, la utilización efectiva de diferentes métricas para evaluar y comparar modelos de regresión es una habilidad fundamental en la ciencia de datos. Cada métrica proporciona información valiosa sobre varios aspectos del rendimiento del modelo. Un enfoque equilibrado que considere múltiples métricas puede ofrecer una comprensión más completa y precisa del rendimiento del modelo, lo que es crucial para tomar decisiones informadas en la selección y aplicación de modelos de regresión.

4.2. Comparación de Modelos Basada en Métricas




Ilustración 4. Representación a nivel conceptual y gráfica del ciclo de un modelo Machine Learning.

Fuente: [Web](#)

A continuación, se muestra unos pasos que siguen una posible estrategia para comparar modelos de regresión:

1. Establecer un Marco de Referencia Común

Al comparar modelos, es esencial tener un marco de referencia común. Esto significa utilizar el mismo conjunto de datos para entrenar y probar cada modelo y aplicar las mismas métricas de rendimiento. Por ejemplo, si se utilizan datos de ventas para predecir tendencias del mercado, todos los modelos deben evaluarse en este conjunto de datos específico.

2. Uso de Validación Cruzada

La validación cruzada es una técnica efectiva para comparar modelos. Como vimos en unidades anteriores, consiste en dividir los datos en múltiples subconjuntos y utilizar cada uno de ellos para evaluar el rendimiento del modelo. Esto ayuda a garantizar que la comparación sea justa y robusta, mitigando el riesgo de sobreajuste a un único conjunto de datos de prueba.

3. Selección de métricas según naturaleza del Problema

La elección de la métrica depende en gran medida de la naturaleza del problema. Por ejemplo, en problemas donde los errores grandes son más críticos (como en las predicciones financieras), el RMSE podría ser más indicado debido a su sensibilidad a estos errores.

Dependiendo de los algoritmos se usen en la práctica y con qué librerías python, sería posible que dicha librería tenga por defecto implementada dichas métricas. En caso contrario tocaría al científico de datos crearlas. El framework más usado en el mundo de la ciencia del dato es scikit-learn.org donde podrás encontrar numerosas métricas ya implementadas

4. Ejecución de diferentes algoritmos y selección del más idóneo

Esto implica probar una variedad de algoritmos, ajustar sus hiperparámetros y evaluar su rendimiento utilizando métricas relevantes. La elección del algoritmo adecuado depende de varios factores, como la naturaleza de los datos, la complejidad del problema y los objetivos específicos. Es esencial considerar la capacidad de generalización, el tiempo de entrenamiento y la interpretabilidad del modelo. La selección del algoritmo óptimo no es una decisión única, sino un proceso iterativo que busca maximizar el rendimiento y la utilidad práctica del modelo de regresión.

En la práctica, el framework más usado en el mundo de la ciencia del dato es scikit-learn.org donde podrás encontrar números [algoritmos de regresión](#) ya implementados. En la actualidad, si se utilizan técnicas de Deep Learning existen otros framework open source como Tensorflow/Keras o Pytorch.

En este punto, me gustaría mostrar un resumen no exhaustivo 100% pero práctico de cómo podrían hacer una selección de métricas de regresión y algoritmos supervisados de regresión visto en la anterior unidad:

- Los algoritmos lineales como Regresión Lineal, Ridge y Lasso pueden funcionar bien con métricas como MSE, RMSE, MAE, R2, y R-ajustado2.
- Los algoritmos basados en árboles como Árbol de Decisión y Random Forest pueden funcionar bien con métricas como MSE, RMSE, MAE, y R2.
- Algoritmos de ensamblado como Gradient Boosting y AdaBoost también se pueden evaluar con métricas similares a las de árboles y a menudo ofrecen un mejor rendimiento. En el caso de estos dos algoritmos decir:

Gradient Boosting construye un conjunto de árboles de decisión de manera secuencial, donde cada nuevo árbol se ajusta a los errores cometidos por el conjunto anterior. Esto significa que la métrica principal que se usa para evaluar Gradient Boosting es similar a la de árboles de decisión, como MSE, RMSE o MAE. Éste puede capturar relaciones no lineales y manejar datos ruidosos, pero puede ser propenso al sobreajuste si no se ajustan los hiperparámetros adecuadamente.

AdaBoost también se utiliza principalmente en problemas de clasificación, pero se puede aplicar a la regresión, se ajusta una secuencia de modelos de aprendizaje débil, y cada modelo

se pondera según su capacidad para corregir errores anteriores. Al igual que Gradient Boosting, las métricas de regresión como MSE o MAE se utilizan para evaluar el rendimiento de AdaBoost en problemas de regresión. También puede ser sensible al sobreajuste y requiere una configuración adecuada de hiperparámetros.

5. Interpretación de Resultados

Para interpretar resultados y comparar métricas de regresión entre diferentes algoritmos, primero, comprende las métricas, enfócate en una métrica principal que se alinee con tus objetivos, pero considera otras métricas para obtener una imagen completa. Utiliza gráficos y análisis de residuos, si es posible, y realiza pruebas estadísticas si es necesario. La elección debe contextualizarse según el dominio y los objetivos específicos del problema. Documenta tus hallazgos de manera clara y concisa para comunicar efectivamente los resultados.

Estos puntos anteriores proporcionan una guía clara y sencilla para entender cómo se pueden comparar diferentes modelos de regresión utilizando diversas métricas, considerando la naturaleza del problema y la interpretación de los resultados, acompañados de ejemplos prácticos y ejercicios para aplicar estos conceptos.

4.3. Mejora del Modelo Basada en Retroalimentación de Métricas

La optimización de modelos de regresión es un proceso dinámico y continuo que requiere no sólo la comprensión y aplicación de métricas de rendimiento, sino también la capacidad de interpretar estas métricas y utilizarlas para mejorar sistemáticamente el modelo.

Esta fase del modelado, donde las métricas sirven como una fuente de retroalimentación vital, es crucial para afinar la precisión y eficacia de los modelos. En lugar de ver las métricas como simples indicadores de rendimiento, este enfoque las considera como herramientas diagnósticas que pueden revelar debilidades, fortalezas y oportunidades de mejora en los modelos. Al utilizar esta retroalimentación de manera efectiva, los científicos de datos pueden realizar ajustes informados, desde la sintonización fina de parámetros hasta la reestructuración conceptual del modelo, asegurando que este se adapte de manera óptima a los datos y al problema en cuestión.

Este proceso iterativo y reflexivo de mejora basado en la retroalimentación de métricas es fundamental para el desarrollo de soluciones de modelado robustas y confiables en el campo de la ciencia de datos. A continuación, mostramos un conjunto de fases que describe fases del proceso de mejora del modelo a través de la retroalimentación de métricas:

1. Interpretación de Métricas y Ajuste del Modelo

La mejora del modelo comienza con un análisis detallado de las métricas obtenidas. Por ejemplo, un alto MSE o RMSE indica errores sustanciales en las predicciones del modelo. Este análisis debe ir más allá de la mera observación de los valores numéricos, profundizando en lo que estos errores significan en el contexto del problema específico.

Por otro lado, se puede examinar los patrones en los errores. Por ejemplo, si los errores son sistemáticamente más grandes en ciertas condiciones o para ciertos subconjuntos de datos, esto

puede indicar la necesidad de ajustar el modelo o incluir variables adicionales que capturen estas condiciones.

2. Estrategias de Mejora Basadas en Retroalimentación

Basándose en la retroalimentación de las métricas, se puede llegar a ajustar los parámetros del modelo las veces que sea necesaria. Por ejemplo, en un modelo de regresión, esto podría implicar cambiar el grado de regularización o ajustar los parámetros de un algoritmo de aprendizaje específico para reducir el sobreajuste o el subajuste.

También se puede llegar al caso que se detecte que ciertas variables no contribuyen significativamente a la precisión del modelo, considera la posibilidad de eliminarlas (poda). Por otro lado, la inclusión de nuevas variables podría mejorar el rendimiento del modelo si se identifican factores previamente no considerados.

3. Retroalimentación Continua y Ciclo de Mejora

La mejora del modelo debe ser un proceso iterativo. Utiliza las métricas no como un fin, sino como un medio para un ajuste continuo. Este enfoque implica volver a evaluar periódicamente el modelo con nuevas métricas y realizar ajustes según sea necesario.

No tengas miedo de experimentar con diferentes enfoques de modelado basados en la retroalimentación de las métricas. Cada ajuste o cambio debe ser validado con un conjunto de datos de prueba o a través de técnicas de validación cruzada para asegurar que las mejoras son genuinas y no el resultado de adaptarse a un conjunto de datos específico.

En resumen, el desarrollo de estas fases descritas en el desarrollo de un modelo una guía para utilizar las métricas no solo como un medio de evaluación, sino también como una herramienta crucial para la mejora continua de los modelos de regresión.

5. Tema 3: Contextualización Práctica de las Métricas en Modelos de Regresión

En el vasto y dinámico mundo de la ciencia de datos, la teoría y la práctica a menudo convergen en el uso de modelos de regresión. Este tercer tema se centra en la aplicación real y tangible de las métricas de rendimiento en diversos escenarios del mundo real. La comprensión profunda de cómo se aplican estas métricas -como el MSE, RMSE, MAE y R^2 , y en situaciones prácticas es esencial para cualquier científico de datos. No solo proporcionan una base para evaluar y mejorar los modelos de regresión, sino que también son fundamentales para traducir los resultados analíticos en decisiones informadas y comunicaciones efectivas, especialmente en entornos empresariales y de investigación.

Este tema profundiza en cómo las métricas de rendimiento pueden influir en la toma de decisiones críticas, en la presentación de resultados a audiencias no técnicas y en la formulación de estrategias basadas en datos. Se mencionan casos de estudio y ejemplos del mundo real donde la correcta interpretación y aplicación de estas métricas han desempeñado roles clave, ilustrando su importancia no solo como números abstractos, sino como herramientas esenciales en la narrativa de la ciencia de datos. Este enfoque práctico y contextualizado es crucial para entender cómo las métricas de regresión se aplican más allá del ámbito teórico, afectando directamente los resultados y la eficiencia en diversos sectores.

5.1. Métricas de Rendimiento en el Mundo Real

Las métricas de rendimiento en modelos de regresión no son sólo conceptos teóricos confinados al mundo académico; su aplicación e impacto se extienden profundamente en escenarios del mundo real, influyendo en decisiones críticas en múltiples sectores. Este punto se enfoca en desentrañar cómo estas métricas, comúnmente discutidas en términos de datos y algoritmos, se traducen en herramientas prácticas para la toma de decisiones, la optimización de procesos y la formulación de estrategias.

Al examinar cómo se aplican el MSE, RMSE, MAE y R^2 , etc en contextos reales, obtenemos una perspectiva valiosa sobre su relevancia y utilidad fuera del ámbito de la teoría estadística. Desde la predicción de tendencias del mercado hasta la mejora en los servicios de salud, estas métricas desempeñan un papel crucial en la modelación de datos y en la interpretación de sus resultados, convirtiéndose en pilares fundamentales para la toma de decisiones basada en evidencia. Su aplicación efectiva es un testimonio de cómo la ciencia de datos, mediante estas métricas, facilita decisiones más informadas y estrategias más eficientes en el mundo real.

1. Aplicación en Diversos Sectores

Las métricas de rendimiento en modelos de regresión encuentran su aplicación en una amplia gama de sectores, desde el financiero hasta el de salud. Por ejemplo, en el sector financiero, el MSE y RMSE son cruciales para evaluar modelos de predicción de riesgos crediticios o de mercado, donde la precisión en las predicciones puede tener un impacto directo en las decisiones de inversión. En el ámbito de la salud, estas métricas se utilizan para evaluar modelos predictivos en diagnósticos médicos, donde la precisión es vital para el tratamiento y la prevención de enfermedades.

2. Optimización de Procesos y Servicios

En la industria y los servicios, las métricas como el MAE y R^2 se aplican para mejorar la eficiencia operativa y la satisfacción del cliente. Por ejemplo, en la logística, un modelo de regresión con un bajo MAE en la predicción de tiempos de entrega puede ayudar a optimizar las rutas de entrega y mejorar la experiencia del cliente.

3. Toma de Decisiones Basada en Datos en Negocio

Las métricas de rendimiento son fundamentales en la toma de decisiones basada en datos en el ámbito empresarial. Por ejemplo, un modelo de regresión que utiliza el R^2 para evaluar la influencia de las campañas de marketing en las ventas puede proporcionar insights valiosos para la asignación de presupuestos y estrategias de marketing. Una alta correlación indicada por un R^2 elevado puede justificar la inversión en ciertas campañas de marketing.

5.2. Contexto de implementaciones de algoritmos existentes

Como mencionamos anteriormente, el framework más utilizado a día de hoy por los científicos de datos es [scikit-learn](#), donde podrás encontrar de funcionalidades, entre ellas lo que vemos en esta sección que es [algoritmos supervisados de regresión](#) con muchas de las [métricas de regresión](#) vistas en la unidad.

5.3. Comunicación de Resultados a un Público Amplio

La habilidad para comunicar efectivamente los resultados obtenidos de las métricas de modelos de regresión es tan crucial como la capacidad de generar estos modelos. Este punto, "Comunicación de Resultados", explora el arte y la ciencia de traducir datos complejos y análisis estadísticos en información comprensible y accionable, especialmente para un público no técnico.

En el mundo interconectado y basado en datos de hoy, los científicos de datos no solo necesitan ser adeptos en el manejo de números, sino también en la comunicación de sus hallazgos de manera que sean accesibles y útiles para quienes toman las decisiones, que a menudo no tienen una formación técnica en estadística.

Esta sección abordará pautas sencillas y efectivas para presentar los resultados de las métricas y la importancia de la claridad y precisión en la comunicación a público que en la mayoría de los casos será de negocio:

1. Simplificación y Visualización de Datos

Una de las estrategias más efectivas es la simplificación de los resultados a través de visualizaciones como gráficos y tablas que pueden transformar conjuntos de datos complejos y métricas abstractas en formatos visuales más digeribles y entendibles. Realiza comparaciones significativas entre los diferentes algoritmos y métricas. Destaca las fortalezas y debilidades de cada enfoque y cómo contribuyen a la comprensión del problema.

2. Narrativa de Datos

Desarrollar una narrativa alrededor de los datos es esencial. Esto implica contar una historia con los resultados, destacando los puntos clave y su relevancia, y evitando jerga técnica innecesaria.

El objetivo es hacer que los hallazgos sean no sólo comprensibles, sino también interesantes y relevantes para el público. Proporciona un resumen conciso de los hallazgos clave al final de la presentación. Esto ayuda a que la audiencia retenga la información más importante

3. Importancia de la claridad y la precisión en la comunicación

Evita malentendidos a través de claridad y precisión en el lenguaje utilizado, son fundamentales para evitar malentendidos o interpretaciones erróneas de los datos. Esto es especialmente importante en contextos donde los resultados de las métricas guían decisiones críticas.

Fomenta la interacción con la audiencia. Anima a hacer preguntas y proporciona respuestas claras y concisas. Esto promueve un mejor entendimiento y clarificar posibles dudas.

4. Fomentar la Confianza en los Datos

Contextualiza los resultados dentro del problema o la pregunta que estás abordando. Explica por qué las métricas y los algoritmos son importantes y cómo se relacionan con los objetivos del proyecto con una comunicación clara y precisa ayudando a fomentar la confianza en los resultados presentados. Cuando el público entiende y confía en los hallazgos presentados, es más probable que respalde las decisiones o estrategias basadas en estos datos.

En resumen, la comunicación efectiva de los resultados de las métricas es un puente vital entre el análisis técnico y su aplicación práctica. Al dominar esta habilidad, los científicos de datos no sólo amplifican el impacto de su trabajo, sino que también se aseguran de que los insights obtenidos de los modelos de regresión sean utilizados de manera óptima en la toma de decisiones y la formulación de políticas.

5.4. Casos de Uso y Estudios de Caso

El punto "Estudios de Caso y Aplicaciones" se centra en la exploración práctica de cómo las métricas de rendimiento en modelos de regresión han sido implementadas en situaciones reales, resaltando su impacto y utilidad a través de diversos sectores. Esta sección busca no solo demostrar la aplicabilidad de estas métricas en el mundo real, sino también proporcionar una comprensión profunda de su influencia en la toma de decisiones y la optimización de procesos en diferentes industrias. A través del análisis de estudios de caso concretos, se ilustrará el papel fundamental que las métricas como MSE, RMSE, MAE y R^2 juegan en entornos empresariales, científicos y sociales. Esta exploración permitirá a los profesionales y estudiantes de ciencia de datos ver cómo la teoría se traduce en práctica, proporcionando una visión valiosa de la versatilidad y relevancia de estas métricas en diversos contextos.

1. Estudios de Caso en el Sector Financiero:

Por ejemplo, en el sector financiero, un estudio de caso podría destacar cómo el uso del RMSE en modelos de predicción de riesgos crediticios ayudó a una institución financiera a minimizar pérdidas y optimizar sus estrategias de préstamo.

2. Aplicaciones en Salud Pública

En el ámbito de la salud, se puede examinar cómo el uso de MAE en modelos predictivos de propagación de enfermedades contribuyó a una mejor planificación y respuesta en situaciones de emergencia sanitaria.

3. Industria y Manufactura

En la industria y la manufactura, las métricas de regresión se utilizan para mejorar la eficiencia operativa, por ejemplo, utilizando el MSE para optimizar los procesos de control de calidad.

4. Sector de Servicios y Retail

En el comercio y servicios, estas métricas pueden ayudar a entender mejor el comportamiento del cliente y a mejorar la experiencia del usuario. Un caso podría ser el uso del R^2 para evaluar la efectividad de diferentes estrategias de marketing en las ventas.

5. Comparación en un Caso de Estudio de Predicción de Precios de Viviendas:

Podrías realizar un ejercicio práctico donde se comparan diferentes modelos de regresión para predecir los precios de las viviendas. Aquí, se pueden aplicar tanto el MSE como el RMSE para evaluar los errores de predicción y el R^2 para determinar qué porcentaje de la variabilidad en los precios es explicado por cada modelo.

5. Ejercicio Práctico de Predicción del Tiempo de Entrega:

Otro ejercicio podría involucrar la comparación de modelos en la predicción del tiempo de entrega en una empresa de logística. Aquí, el MAE sería útil para medir la precisión de las predicciones, ya que cada error, ya sea grande o pequeño, tiene un impacto significativo en la satisfacción del cliente.

Este enfoque en estudios de caso y aplicaciones prácticas demuestra claramente el papel esencial que juegan las métricas de rendimiento en una amplia gama de industrias, destacando su importancia no solo en el análisis de datos, sino también en la toma de decisiones estratégicas y operacionales en el mundo real.



Ten en cuenta

El científico de datos tiene que ser una pata más de negocio, desde la definición del problema, mapeo de posibles soluciones, selección de modelo y métricas hasta la exposición de resultados enfocados al negocio. “Un modelo sin impacto de negocio no es nada”.

6. Conclusiones

Medir, Comprender, y Transformar: Las Métricas de Regresión como Brújula hacia Decisiones Inteligentes en Ciencia de Datos

En este tema se ha realizado un recorrido sobre Métricas de rendimiento de los Modelos de Regresión. Para cerrar esta unidad, se propone una serie de recomendaciones generales:

- **Evaluar y Optimizar con Precisión:** Las métricas de regresión proporcionan una base sólida para evaluar con precisión el rendimiento de los modelos de regresión. Comprender estas métricas es esencial para ajustar y optimizar modelos, asegurando que se adapten de manera óptima a los datos y resuelvan problemas de negocio de manera efectiva.
- **Influencia en la Toma de Decisiones:** Las métricas de regresión no son solo números; son herramientas poderosas para la toma de decisiones informadas en una variedad de industrias y sectores. Los científicos de datos deben ser capaces de interpretar y comunicar los resultados de estas métricas a audiencias no técnicas, ya que estas decisiones a menudo repercuten en estrategias empresariales, políticas públicas y procesos operativos.
- **Aplicación en el Mundo Real:** Las métricas de regresión tienen un impacto tangible en la resolución de problemas del mundo real. Estas métricas se aplican en una variedad de sectores, desde la industria financiera hasta la salud pública, y juegan un papel clave en la optimización de procesos, la mejora de la eficiencia y la identificación de oportunidades de negocio. Su comprensión y aplicación efectiva son esenciales para cualquier científico de datos que aspire a ser un impulsor de decisiones inteligentes y estratégicas.

7. Bibliografía

V. Plevris , G. Solorzano , N. Bakas , M. Ben Seghier (2022). Investigación sobre el performance de las métricas de regresión. https://www.scipedia.com/public/Plevris_et_al_2022a

Gareth James, Daniela Witten, Trevor Hastie y Robert Tibshirani. Lectura recomendada <https://statlearning.com/> . Trata todos estos temas entrando de lleno en la estadística

Dunia Abas Gzar1, Ali Majeed Mahmood1 y Maythem K. Abbas2 (2018) . Comparative Study of Regression Metrics in Machine Learning - [artículo](#) de investigación que realiza una comparativa exhaustiva de diferentes métricas de regresión en Machine Learning.

Martin Spuler, Andrea Sarasola-Sanz, Niels Birbaumer, Wolfgang Rosenstiel, Ander Ramos-Murguialday (2015). Caso de uso sobre la comparación de métricas para evaluar el rendimiento de métodos de regresión para decodificar señales neuronales <https://pubmed.ncbi.nlm.nih.gov/26736453/>

Material importante para tener en cuenta para ver las métricas de regresión implementados en el framework scikit-learn https://scikit-learn.org/stable/modules/model_evaluation.html#regression-metrics

Material importante para tener en cuenta para ver los algoritmos supervisados de regresión implementados en el framework scikit-learn https://scikit-learn.org/stable/supervised_learning.html

Material fundamental para el entendimiento de conjunto de datos mediante gráficos interesantes para entender su estructura y poder comunicarlo al público objetivo, mediante librerías python open source: [matplotlib](#) y [seaborn](#)

[Lectura recomendada](#) para el mundo de Machine Learning, con un apartado específico sobre modelos lineales.



WELCOME
TO
UAX

UAX

Universidad
Alfonso X el Sabio

GRACIAS

UAX.COM