



Unidad 4b

Series Temporales: Modelos GARCH


Primeros modelos ARCH y GARCH para la varianza

ÁREAS DE APLICACIÓN Y CASOS DE USO: ENTORNOS CON
DATOS ESTRUCTURADOS

Where are we and where are we going?

Hasta ahora, hemos estudiado conceptos como:

- Dependencia lineal
- Datos estacionarios
- Media condicional
- Datos no estacionarios



- Hemos analizado todas las dinámicas potenciales en la media condicional del futuro de una variable aleatoria
- Parece natural ir más allá del modelado de la media condicional y comenzar a explorar otras características del proceso estocástico en estudio
- Nuestro objetivo ahora es poner en práctica el modelado y la predicción de la **varianza condicional**

¿Porque media condicional y incondicional?:

En el análisis de series temporales, como en los modelos ARIMA, se enfoca en modelar la **media condicional** en lugar de la incondicional debido a que el objetivo principal es **predecir el valor futuro de una variable basándose en la información disponible hasta el momento actual**.

La media condicional es la esperanza matemática del valor futuro de una variable, dada la información pasada. En términos de series temporales, se expresa como:

$$E(Y_t | Y_{t-1}, Y_{t-2}, \dots)$$

La media incondicional es simplemente el promedio general de la serie sin considerar ninguna información pasada. En procesos estacionarios, esta media puede ser constante, pero no proporciona información sobre las dinámicas temporales de la serie. En cambio, la media condicional captura cómo los valores pasados influyen en los futuros, lo cual es esencial para la predicción.



Where are we and where are we going?

- Hemos modelado un proceso estocástico descubriendo la **dependencia lineal en el tiempo** contenida en sus funciones de autocorrelación (ACF y PACF).
- Una vez que el modelo estuvo en su lugar, construimos una predicción (**pronóstico puntual e intervalos de confianza**).
- El **pronóstico puntual óptimo a h pasos** fue dado por la expectativa condicional del proceso basada en el conjunto de información I_t .

$$f_{t,h} = E(Y_{t+h} | I_t)$$

- Pero **el mundo también está preocupado por la incertidumbre**: los agentes económicos están interesados no solo en los precios futuros promedio, sino también en las volatilidades futuras de los precios.


Taxicab Pickup Count in Times Square by Time



- La incertidumbre del pronóstico se ha definido como la varianza del error de predicción, es decir:


$$\sigma_{t+h/t}^2 = \text{Var}(Y_{t+h} | I_t)$$

- Como estamos tratando con momentos de segundo orden, es lógico analizar las funciones de autocorrelación del proceso al cuadrado.
- Una vez que hemos encontrado un "buen" modelo lineal para explicar la media condicional del proceso estocástico (residuos que son WN), debemos comprobar si nuestros residuos de ruido blanco son o no **estricto ruido blanco** observando las funciones ACF y PACF de sus valores al cuadrado.
 - Si los residuos al cuadrado muestran estructura en el ACF y PACF, entonces la volatilidad puede ser predicha y se debe encontrar un modelo **no lineal** que capture este comportamiento.
 - Si los residuos al cuadrado no muestran ninguna estructura, entonces la **volatilidad no puede ser predicha** y hemos terminado nuestro modelado.




Vamos a introducir los modelos ARCH para la varianza a través de un ejemplo real: **EurUSD exchange rate**

Evidencia empírica: Tipo de cambio Euro/Dólar estadounidense (EurUsd)




- **No estacionariedad:** la serie temporal original (precios spot diarios) muestra un alto grado de persistencia, por lo que podríamos cuestionar si es no estacionaria. **Otra señal de no estacionariedad es la ACF que disminuye lentamente.**
- Aceptamos la hipótesis nula del test ADF (H_0 : La serie no es estacionaria) , y la función de autocorrelación (ACF) muestra el comportamiento típico de un proceso no estacionario.

Rendimientos (Returns): se calculan como la primera diferencia del logaritmo de los precios; esta es la transformación estacionaria de los precios especulativos.



Los rendimientos **no son normales**



$$r_t = \cancel{r_{t-1}} + \cancel{\epsilon_t}$$

$$r_t = \epsilon_t$$

¿Qué significa esto?


Que los rendimientos no tienen dependencia temporal (no dependen de r_{t-1} , r_{t-2} , etc.) y son puramente **aleatorios**.

No hay estructura que podamos modelar: no hay autocorrelación, ni tendencia, ni patrones predecibles.

Los rendimientos son típicamente no correlacionados: podemos concluir que, en general, se comportan como un proceso de Ruido Blanco (aceptamos la hipótesis nula del test de Box-Pierce). Esto implica que **NO** podemos usar un modelo Lineal para predecir los rendimientos.

Evidencia empírica: Tipo de cambio Euro/Dólar estadounidense (EurUsd)

Los rendimientos tienen volatilidad que varía en el tiempo: los movimientos grandes (pequeños) tienden a ser seguidos por movimientos grandes (pequeños). Hay agrupaciones de actividad (clusters). Este concepto se llama: **Volatility Clustering**. Esto significa que los rendimientos no son procesos independientes porque encontramos dependencia en sus segundos momentos (volatilidad).



Puedes predecir la intensidad del movimiento, pero no su dirección.



- **Los rendimientos al cuadrado muestran una estructura fuerte tanto en las funciones ACF como PACF** (rechazamos la hipótesis nula del test de Box-Pierce; no son ruido blanco estricto). Cuando los **rendimientos** r_t no muestran autocorrelación (ruido blanco), no podemos predecir el valor de r_{t+1} basándonos en r_t , r_{t-1} , etc.
- **Pero si los rendimientos al cuadrado** (o los valores absolutos) muestran autocorrelación, entonces sí podemos predecir la **varianza condicional o la volatilidad de los rendimientos futuros**.
- Eso significa que **la magnitud** de los movimientos (grandes o pequeños) sí es predecible, aunque el signo (positivo o negativo) del rendimiento no lo sea. (No podemos predecir su valor exacto en este caso)

La familia GARCH: Modelos no lineales para la varianza de una serie temporal


Todos estos hallazgos son muy buenas noticias, porque significa que podríamos proponer modelos para momentos de orden superior a la media, **que capturen la dependencia temporal de cualquier serie financiera**.

Hemos visto empíricamente en las diapositivas anteriores que las series financieras se caracterizan por dependencias no lineales.

Vamos a analizar una de las familias de modelos no lineales más populares para representar estas dependencias y, en consecuencia, obtener estimaciones del riesgo y de las volatilidades asociadas a un determinado activo financiero.

Vamos a estudiar el modelo **GARCH(1,1)** (Bollerslev, 1986).

El modelo no lineal GARCH(1,1) será estimado sobre los residuos de nuestro modelo lineal ajustado **solo si** estos **no** son ruido blanco estricto (**es decir, si existe estructura en los residuos al cuadrado**).



**Generalized
Autoregressive
Conditional
Heteroskedasticity
(GARCH)**

[ˈje-nə-rə-,lɪzd ˈò-(.)tō-ri-ˈgre-siv kən-ˈdɪʃ-nəl ˈhe-tə-,rō-ˈske-,dɑ-ˈsti-sə-tē]

An approach to estimating
the volatility of financial
markets.

La familia GARCH: GARCH(1,1)

Las ecuaciones del modelo **GARCH(1,1)** son las siguientes:

$$y_t = SARIMA(p, d, q) \times (P, D, Q)_S + e_t$$


$$\begin{matrix} e_{t-1} \\ \gamma_{t-1} \end{matrix}$$

donde e_t son los **residuos del modelo lineal**. Los residuos deben ser al menos **ruido blanco (WN)** para que el SARIMA elegido sea un 'buen' modelo.

Si nuestros residuos e_t **no** son **ruido blanco estricto (SWN)**, porque tienen estructura en el segundo momento, entonces pueden ser modelados de la siguiente manera:

$$e_t = \varepsilon_t \sigma_t$$

$$\sigma_t^2 = \omega + \alpha e_{t-1}^2 + \beta \sigma_{t-1}^2$$



donde:

- ε_t son los **residuos del modelo no lineal** (también conocidos como **residuos estandarizados**).
- Los residuos estandarizados deben ser **ruido blanco estricto (SWN)** con **varianza igual a 1**.

En palabras simples:

- ω asegura que siempre haya algo de volatilidad, **aunque no haya shocks**.
- α mide **cómo reacciona** la volatilidad a nuevas noticias o sorpresas.
- β mide **cuánto dura** el efecto de la volatilidad en el tiempo.

Símbolo	Nombre	Interpretación
ω	Término constante	Nivel <u>base de volatilidad</u> ; volatilidad mínima que siempre está presente.
α	Coeficiente ARCH	Impacto del shock reciente (el cuadrado del último error) sobre la volatilidad actual. Captura la respuesta inmediata a las noticias nuevas.
β	Coeficiente GARCH	Persistencia de la volatilidad pasada . Captura cuánto de la volatilidad de ayer sigue vigente hoy.

La familia GARCH: GARCH(1,1)

- Si α es grande $\rightarrow$ la volatilidad **reacciona mucho** a nuevos shocks (nuevas noticias).
- Si β es grande $\rightarrow$ la volatilidad **se mantiene alta** durante varios periodos después de un shock (alta persistencia).

Importante: Para que el modelo sea estable, se requiere que:

$$\alpha + \beta < 1$$

¿Qué son ε_t ?

- Los ε_t son los **residuos del modelo no lineal** (del modelo GARCH).
- Se llaman **residuos estandarizados** porque han sido **ajustados** para que:
 - Tengan **media cero**,
 - Y **varianza constante e igual a 1**.

$$e_t = \varepsilon_t \sigma_t \quad \longrightarrow \quad \varepsilon_t = \frac{e_t}{\sigma_t}$$

$$\sigma_t^2 = \omega + \alpha e_{t-1}^2 + \beta \sigma_{t-1}^2$$

Cuando estandarizamos los residuos, lo que hacemos es **normalizar cada error** e_t dividiéndolo entre su volatilidad condicional σ_t en el instante t . De esta manera, obtenemos un nuevo residuo, llamado ε_t , que debería tener propiedades mucho más limpias: en particular, debería tener una **varianza constante e igual a 1** a lo largo del tiempo.

¿Por qué hacemos todo esto?

El objetivo es asegurarnos de que, una vez que hemos eliminado toda estructura en la media (a través de un modelo lineal como SARIMA) y una vez que hemos modelado la volatilidad (a través de un modelo GARCH), **no quede ninguna dependencia ni patrón detectable en los residuos**.

En otras palabras, los residuos estandarizados ε_t deberían comportarse como un **ruido blanco estricto**, es decir:

- Ser independientes entre sí,
- Tener media cero,
- Tener varianza constante igual a uno,
- No presentar autocorrelación en sus niveles ni en sus cuadrados.

Modelando los **rendimientos diarios logarítmicos** para el tipo de cambio Euro/Dólar:

- Los rendimientos diarios logarítmicos ya son estacionarios y ruido blanco (WN).
- Sin embargo, los rendimientos diarios logarítmicos **no** son **ruido blanco estricto** (SWN), por lo que se puede ajustar un modelo **GARCH(1,1)**.

Si denotamos los rendimientos diarios logarítmicos como r_t , el modelo final es:

$$r_t = \varepsilon_t \sigma_t$$

$$\varepsilon_t = \varepsilon_t \sigma_t$$

$$\varepsilon_t \sim WN$$

$$\varepsilon_t \not\sim SWN$$

$$\varepsilon_t \sim SWN \checkmark$$

$$\sigma_t^2 = 1.239 \times 10^{-7} + 3.142 \times 10^{-2} e_{t-1}^2 + 9.654 \times 10^{-1} \sigma_{t-1}^2$$

Donde los residuos estandarizados ε_t son **ruido blanco estricto**, aunque **no están normalmente distribuidos**.

- **MeanForecast** es la predicción puntual (**es constante, ya que no se encontró ningún modelo ARMA para los rendimientos logarítmicos**).

- **MeanError** es el error de pronóstico que se utiliza para construir los intervalos de confianza **cuando no** se estima ningún modelo GARCH para los residuos.

- **StandardDeviation** es el error de pronóstico que se utiliza para construir los intervalos de confianza **cuando sí** se estima un modelo GARCH para los residuos.

$E(y_t y_{t-1})$	meanForecast	meanError	standardDeviation
1	3.096541e-05	0.004032701	0.004032701
2	3.096541e-05	0.004041667	0.004041667
3	3.096541e-05	0.004050584	0.004050584
4	3.096541e-05	0.004059453	0.004059453
5	3.096541e-05	0.004068274	0.004068274

```
from arch import arch_model
import numpy as np
import pandas as pd

# Suponiendo que 'r' es una serie de rendimientos diarios logarítmicos
# Aquí generaríamos un ejemplo ficticio
np.random.seed(42)
r = np.random.normal(0, 1, 1000) # Datos simulados; reemplazar por los datos reales

# Ajustar un modelo GARCH(1,1)
model = arch_model(r, vol='Garch', p=1, q=1, mean='Zero', dist='normal')
garch_fit = model.fit(dispatch='off')

# Mostrar el resumen del modelo
print(garch_fit.summary())
```

En nuestro ejemplo, **MeanError** y **StandardDeviation** son iguales porque no hay estructura lineal en nuestros datos.

Si tuviéramos, por ejemplo, un modelo **AR(1) + GARCH(1,1)**, la salida sería la siguiente:

	meanForecast	meanError	standardDeviation
1	0.02400508	1.210581	1.210581
2	0.05048521	1.499210	1.235003
3	0.06907673	1.639870	1.257473
4	0.08212970	1.720274	1.278185
5	0.09129410	1.772503	1.297306

En este caso, el **MeanForecast** cambia a lo largo del tiempo (ya que tenemos un modelo AR(1) para la media), y el **MeanError** y la **StandardDeviation** son diferentes.

En este caso, la **StandardDeviation** (estimada por el modelo GARCH) es **menor** que el **MeanError** (estimado por el AR), ya que comenzamos a predecir en un **período de baja volatilidad**.

- Finalmente, la construcción de los intervalos de confianza de predicción es sencilla:

$$\text{meanForecast} \pm 1,96 \times \text{standardDeviation}$$

$$\hat{y}_t \pm 1,96 \times \hat{\sigma}_t$$

- Como es habitual, este es un intervalo de confianza del 95% bajo la suposición de distribución normal.

- Pero **la serie de rendimientos no está normalmente distribuida** (es simétrica, pero presenta exceso de curtosis; es decir, colas más pesadas que la distribución normal).

- En este caso, se puede construir un mejor intervalo de confianza asumiendo que los rendimientos siguen una **distribución t de Student**.

- La distribución t de Student se caracteriza por sus grados de libertad, que pueden ser estimados a partir de la serie de rendimientos.
- Usando las tablas de la distribución t de Student, podemos encontrar el percentil correspondiente al 95% para sustituir el valor 1,96 en la fórmula.

Especificación de un modelo ARCH(q)

Los modelos ARCH (AutoRegressive Conditional Heteroskedasticity) tienen su origen en un artículo de ENGLE (1982), en el que se pretendía obtener una predicción adecuada para la inflación en el Reino Unido, sujeta a fuerte volatilidad y con períodos de especial calma o de especial agitación.

El proceso ARCH(q) viene definido por la siguiente expresión:

$$\begin{aligned} y_t &= \varepsilon_t \sigma_t \\ \sigma_t^2 &= \omega + \sum_{i=1}^q \alpha_i y_{t-i}^2 \end{aligned} \quad \longrightarrow \quad \begin{aligned} &\text{Si:} \\ y_t &= \varepsilon_t \sim \text{iid}(0, \sigma^2) \end{aligned}$$

Los modelos ARCH fueron introducidos con el objetivo de **capturar situaciones en las que la varianza de los errores no es constante, sino que depende del pasado**, como en los periodos de alta o baja volatilidad en variables económicas como la inflación o el rendimiento financiero.

Donde:

- $\omega > 0, \alpha_i \geq 0$: para asegurar que la varianza condicional sea siempre positiva.
- La varianza en el tiempo t depende de los **errores pasados al cuadrado**.
- ε_t **es un proceso i.i.d. con media cero y desviación típica igual a uno** Esto significa que ε_t son **innovaciones aleatorias estándar**, independientes e idénticamente distribuidas. Este término sirve como "**ruido base**" sobre el que se construye la varianza condicional del modelo.
- Al tener varianza unitaria, permite que la varianza total de y_t quede determinada únicamente por σ_t^2 .
- Si no tuviesemos ε_t , y_t dejaría de ser aleatorio, estarías diciendo que el valor observado del error es igual a su desviación estándar lo cual no tiene sentido estadístico.

$$\begin{cases} y_t = \varepsilon_t \sigma_t \\ \sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i y_{t-i}^2 \end{cases}$$

En resumen: ¿Qué hace entonces ε_t ?

- Introduce el **componente estocástico** (aleatorio) del modelo.
- Le da a y_t la posibilidad de variar de forma **impredecible**, pero controlada por σ_t .
- Es lo que hace que dos momentos con la misma varianza condicional puedan dar valores distintos de y_t .

Especificación de un modelo ARCH(1): Propiedades

$$\varepsilon_t \sim i.i.d$$

1) La esperanza marginal y condicional de y_t es cero:

Porque $y_t = \varepsilon_t \sigma_t$

$$\forall \mathbb{E}(\varepsilon_t) = 0 \Rightarrow \mathbb{E}(y_t) = 0$$

$$\mathbb{E}(y_t) = \mathbb{E}(\varepsilon_t) \mathbb{E}(\sigma_t) \rightarrow 0$$

2) La varianza condicional de y_t depende de los valores al cuadrado:

$$\sigma_t^2 = \omega + \alpha_1 y_{t-1}^2$$

$$\text{Var}(y_t) = \sigma^2 = \omega + \alpha_1 \sigma^2$$

3) La varianza marginal de y_t es constante:

$$\mathbb{E}(y_t^2) = \mathbb{E}(y_{t-1}^2)$$



$$\text{Var}(y_t) = \sigma^2 = \omega + \alpha_1 \sigma^2$$

$$\sigma^2 = \frac{\omega}{1 - \alpha_1}$$

Tipo de varianza	Fórmula	¿Varía en el tiempo?	¿Condicionada al pasado?
Condicional σ_t^2	$\omega + \sum \alpha_i y_{t-i}^2$	Sí	Sí
Marginal (o incondicional)	$\frac{\omega}{1 - \sum \alpha_i}$	No (si es estacionario)	No

ARCH permite **predecir la volatilidad futura**, ARCH no es un modelo para la media, sino para la volatilidad condicional.

Esto es clave en finanzas para estimar **riesgo, intervalos de confianza y valor en riesgo (VaR)**.

La forma de hacerlo es usando las fórmulas recursivas que parten de las últimas observaciones disponibles.

Ejemplo: Modelo AR(1) – ARCH(1)

En este ejemplo tendremos un modelo para la **media** (por ejemplo, un AR(1)) y un modelo para la **varianza condicional** (ARCH(1)). Así tendremos un ejemplo de cómo se combinan **predicción de tendencia** y **predicción de volatilidad**.

$$y_t = \mu + \phi y_{t-1} + u_t \quad (\text{AR(1) para la media})$$

$$u_t = \varepsilon_t \cdot \sigma_t$$

$$\sigma_t^2 = \omega + \alpha_1 u_{t-1}^2 \quad (\text{ARCH(1) para la varianza})$$

Valor esperado de y_t dado el pasado:

$$\mathbb{E}(y_t | \mathcal{F}_{t-1}) = \mu + \phi y_{t-1}$$

Parte	Significado
$\mu + \phi y_{t-1}$	Predice el valor medio de y_t dado el pasado (tendencia o media esperada)
u_t	Es el residuo del modelo (parte impredecible del valor real respecto al esperado)
σ_t^2	Es la varianza condicional del error, depende del residuo pasado al cuadrado
$\varepsilon_t \sim N(0, 1)$	Ruido blanco estándar, es la fuente de aleatoriedad

Varianza condicional de y_t dado el pasado:

$$\text{Var}(y_t | \mathcal{F}_{t-1}) = \sigma_t^2 = \omega + \alpha_1 u_{t-1}^2$$

Esperamos que y_t esté en torno a 1, pero...

...con una varianza de 2.35, lo que indica **incertidumbre** o posible dispersión.

En lugar de predecir solo un número, ahora también **sabemos cuán confiable es esa predicción**.



Ejemplo numérico:

$$\underline{\mu = 0}, \underline{\phi = 0.5} \quad y_{t-1} = 2$$

$$\underline{\omega = 1}, \underline{\alpha_1 = 0.6} \quad u_{t-1} = -1.5$$



Paso 1: Predicción de la media

$$\mathbb{E}(y_t | \mathcal{F}_{t-1}) = 0 + 0.5 \cdot 2 = 1$$

Paso 2: Predicción de la varianza condicional

$$\sigma_t^2 = 1 + 0.6 \cdot (-1.5)^2 = 1 + 0.6 \cdot 2.25 = 1 + 1.35 = 2.35$$

¿Que cambia entre ARCH y GARCH?

El modelo ARCH(q) supone que la **varianza condicional** del error en un instante t depende de los **errores al cuadrado en periodos anteriores**:

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$$

Sin embargo, cuando el número de retardos necesarios (el valor de q) es grande, la estimación del modelo se vuelve compleja y poco eficiente. Para superar esta limitación, **Bollerslev (1986)** propuso una generalización conocida como el modelo **GARCH (Generalized ARCH)**.

El modelo **GARCH(p, q)** extiende el ARCH(q) al permitir que la **varianza condicional** dependa no solo de los errores pasados al cuadrado (como en ARCH), sino también de las **varianzas condicionales pasadas**. Esto lo hace más flexible y eficiente para capturar la persistencia de la volatilidad. La fórmula general es:


$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Este modelo tiene **tres componentes** clave:

1. ω : Nivel base de volatilidad (media a largo plazo).
2. α : Impacto de nuevas noticias (errores recientes $\rightarrow$ efecto ARCH).
3. β : Persistencia de la volatilidad pasada (memoria del proceso $\rightarrow$ efecto GARCH)

¿Por qué es mejor GARCH que ARCH (en muchos casos)?

1. Menos parámetros, misma potencia predictiva
2. Mejor modelación de la persistencia de la volatilidad



“Si hoy hubo mucha volatilidad, mañana también habrá”

ARCH vs GARCH

Caso

Datos financieros con clústeres de volatilidad

Muchos rezagos necesarios en ARCH

Series con volatilidad prolongada

Series con picos de varianza aislados

Solo choques inmediatos afectan la varianza

¿Usar GARCH?



Sí



Sí



Sí



Mejor ARCH



Mejor ARCH

¿Por qué?

Captura mejor la persistencia

GARCH reduce la cantidad de parámetros

ARCH corta demasiado rápido la memoria

GARCH puede ser excesivo

Si no hay memoria de la varianza pasada

