



Unidad 2

Series Temporales: Modelos SARIMA

Primeros modelos SARIMA para series temporales

ÁREAS DE APLICACIÓN Y CASOS DE USO: ENTORNOS CON
DATOS ESTRUCTURADOS





Segunda evaluación individual

Después de haber introducido los modelos ARIMA (Autoregressive Integrated Moving Average), es importante abordar situaciones donde los datos presentan patrones estacionales. En estos casos, los modelos **SARIMA** (Seasonal ARIMA) extienden ARIMA para capturar la estacionalidad en la serie temporal.

El modelo ARIMA es efectivo para capturar tendencias y fluctuaciones generales en una serie temporal, pero no maneja bien patrones que se repiten en intervalos fijos, como:

- Ventas que aumentan cada diciembre.
- **Temperaturas más altas en verano y más bajas en invierno.**
- Producción agrícola con ciclos anuales.

Si aplicamos ARIMA directamente en estos casos, **los residuos pueden seguir mostrando patrones estacionales**, indicando que el modelo no está capturando toda la estructura de los datos.



El modelo **SARIMA(p,d,q) x (P,D,Q)** agrega una componente estacional al modelo ARIMA, con los siguientes parámetros adicionales:

- P**: Número de términos autorregresivos estacionales.
- D**: Grado de diferenciación estacional.
- Q**: Número de términos de media móvil estacionales.
- s**: Período de la estacionalidad (ejemplo: 12 para datos mensuales con ciclos anuales, 7 para datos diarios con ciclos semanales).

La clave del modelo SARIMA es la diferenciación estacional **D**, que se define como:

$$Y_t^* = Y_t - Y_{t-s}$$

Es decir, en lugar de restar cada valor con el inmediatamente anterior (como en una diferenciación normal), restamos con el valor **s períodos atrás**. Esto ayuda a eliminar la estacionalidad de la serie.

Ejemplo Práctico:

Supongamos que tenemos **datos mensuales de ventas de una tienda** y notamos que hay un **pico cada diciembre**. En este caso:



- $s=12$ porque la estacionalidad es anual.
- Aplicamos una diferenciación estacional de orden **D=1**, lo que significa que tomamos la diferencia entre el mes actual y el de hace 12 meses.
- Luego, aplicamos un modelo SARIMA sobre la serie transformada para capturar las tendencias y fluctuaciones restantes.

Característica	ARIMA(p,d,q)	SARIMA(p,d,q) x (P,D,Q)_s
Captura tendencia	✓	✓
Captura estacionalidad	✗	✓
Usa diferenciación estándar	✓	✓
Usa diferenciación estacional	✗	✓

The Box-Jenkins Methodology

La metodología de Box-Jenkins para ajustar un modelo SARIMA es la siguiente:

- 1) Decidir sobre la transformación para la estacionariedad**
 - a. Graficar la serie
 - b. Correlograma (ACF y PACF)
 - c. Prueba de Dickey-Fuller
- 2) Determinar el modelo SARIMA estacionario que mejor se ajuste a las autocorrelaciones estimadas**
- 3) Estimar los parámetros mediante Máxima Verosimilitud (Maximum Likelihood)**
- 4) Obtener los residuos y verificar si son ruido blanco**
- 5) Pronóstico: obtener predicciones puntuales e intervalos de confianza**



Modelos Autorregresivos (S-AR)

Un ciclo estacional es una fluctuación periódica en los datos asociada con el calendario.

✓ **Muchas actividades económicas muestran patrones estacionales:** las ventas minoristas son más altas durante los días festivos, se venden más boletos de avión durante el verano, los precios y la demanda de electricidad son más altos durante los días laborales.


Este comportamiento específico puede capturarse con los **modelos AR y MA estacionales**. (S-AR, S-MA)

✓ Si tenemos **datos trimestrales**, el **parámetro estacional**, denotado por "s", es igual a 4, ya que el ciclo estacional se repite cada cuatro observaciones (el invierno de hoy se relaciona con el invierno siguiente, etc.).

✓ Para **datos mensuales**, el parámetro estacional es $s = 12$; para **datos diarios**, $s = 7$, y así sucesivamente.

Además, la **ACF decae suavemente hacia cero**, pero las autocorrelaciones significativas ocurren en múltiplos de la frecuencia de los datos, es decir: s , $2s$, etc.

El orden del proceso se refleja en el número de picos significativos en la **PACF**.



S-AR(1)

Included observations: 4201

Autocorrelation	Partial Correlation	AC	PAC
		1 -0.020	-0.020
		2 -0.027	-0.027
		3 -0.022	-0.023
		4 0.796	0.796
		5 -0.007	0.030
		6 -0.024	0.004
		7 -0.025	-0.009
		8 0.641	0.021
		9 0.012	0.027
		10 -0.017	0.014
		11 -0.014	0.036
		12 0.515	-0.001
		13 0.021	-0.005
		14 -0.011	0.004
		15 -0.001	0.015
		16 0.414	0.002
		17 0.025	-0.001
		18 -0.004	0.006
		19 0.004	-0.007
		20 0.337	0.012
		21 0.028	0.004

S-AR(2)

Included observations: 4197

Autocorrelation	Partial Correlation	AC	PAC
		1 -0.018	-0.018
		2 -0.109	-0.109
		3 -0.022	-0.026
		4 0.729	0.725
		5 -0.003	0.022
		6 -0.116	-0.033
		7 -0.032	-0.021
		8 0.668	0.290
		9 0.005	0.010
		10 -0.097	0.033
		11 -0.035	0.000
		12 0.560	0.005
		13 0.016	0.008
		14 -0.097	-0.005
		15 -0.033	0.014
		16 0.485	0.002
		17 0.021	0.003
		18 -0.088	-0.003
		19 -0.037	-0.006
		20 0.417	0.005
		21 0.009	-0.040

Modelos Autorregresivos (S-MA)

La estacionalidad estocástica también puede especificarse utilizando modelos **MA**.

Representamos una serie **S-MA(1)** y **S-MA(2)** para datos trimestrales, junto con sus correspondientes **ACF** y **PACF**.



La **ACF** muestra una fuerte evidencia de un componente **MA estacional**, pero en los múltiplos de la frecuencia de los datos.

La **PACF** decae hacia cero de manera alternante.


El orden del proceso se refleja en el número de picos significativos en la **ACF**.

Además, la **PACF** decae suavemente hacia cero, pero las autocorrelaciones parciales significativas ocurren en múltiplos de la frecuencia de los datos, es decir: **s, 2s, etc.**


El orden del proceso se refleja en el número de picos significativos en la **ACF**.



S-MA(1)



S-MA(2)



En la práctica, los datos de series temporales combinan ciclos **estacionales** y **no estacionales**.

Un enfoque común en el modelado de estas series es asumir que ambos ciclos interactúan de manera **multiplicativa**.

Supongamos que tenemos una serie temporal **trimestral** con un **ciclo estacional S-ARMA(1,2)** y un **ciclo no estacional ARMA(2,1)**. El modelo multiplicativo se expresa como:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_4 Y_{t-4} - \phi_1 \phi_4 Y_{t-5} - \phi_2 \phi_4 Y_{t-6} + c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_4 \varepsilon_{t-4} + \theta_8 \varepsilon_{t-8} + \theta_1 \theta_4 \varepsilon_{t-5} + \theta_1 \theta_8 \varepsilon_{t-9}$$

=

$$(1 - \phi_1 L - \phi_2 L^2)(1 - \phi_4 L^4)Y_t = c + (1 + \theta_4 L^4 + \theta_8 L^8)(1 + \theta_1 L)\varepsilon_t$$

donde ε_t es un
proceso de **Ruido**
Blanco



Ejemplos reales donde examinaremos el modelo **SARIMA(p,d,q) x (P,D,Q)**

**Monthly clothing sales in the United States (in
millions \$)**

**Temperatura
en New York**

Serie Temporal: Temperatura en New York

Temperatura en New York




Que modelo se podría aplicar aquí sabiendo que $s = 12$, es decir, que tenemos **datos mensuales**.

Dickey-Fuller = -5.9355, Lag order = 12, p-value = 0.01

alternative hypothesis: stationary

Según el valor $p = 0.01 < 0.05$ por tanto, se acepta la hipótesis alternativa es decir la serie es estacionaria, con el fin de seleccionar las ordenes de (p) y (q) del modelo examinamos las gráficas del ACF y PACF (autocorrelación simple y parcial).



Resultados del modelo SARIMA(1,0,1)×(0,1,3)[12]

Obsérvese los gráficos de la función de autocorrelación parcial PACF, tiene un patrón ondulado y se reduce a cero, lo que sugiere un proceso S-AR(3) o más. La función de autocorrelación ACF, tiene un retraso significativo en una primera conjetura, lo que sugiere un S-MA(1) y quizás también un MA(1). Vamos a intentar con un modelo SARIMA.

Iniciamos con el ajuste del modelo SARIMA (1,0,1)x(0,1,3)[12] a continuación el resultado:

Coeficientes estimados:

Coeficiente	Estimación	Error estándar	Z-valor	p-valor	Significancia
AR(1)	0.7658	0.1170	6.5464	5.89e-11	*** (p<0.001)
MA(1)	-0.5485	0.1510	-3.6316	0.00028	*** (p<0.001)
SMA(1)	-0.9193	0.0732	-12.5612	<2.2e-16	*** (p<0.001)
SMA(2)	-0.1109	0.0839	-1.3224	0.1860	(no significativo)
SMA(3)	0.1614	0.0810	1.9923	0.0463	* (p<0.05)

El modelo **SARIMA** estimado tiene la siguiente estructura:

- **Orden no estacional:** (1,0,1) → AR(1), sin diferenciación, MA(1).
- **Orden estacional:** (0,1,3)[12] → Diferenciación estacional de orden 1, con S-MA(3)

Residuo





Fig. 18 ACF de Residuo

Parece que los Residuos no son Ruido Blanco ☹, pues hay que cambiarlo. Lo afirmo por lo que veo y por el test (Box-Jenkins)



Residuo



Resultados del modelo SARIMA(1,0,1)×(0,1,1)[12]

El coeficiente sma2 no es significativo y el sma3 parece que tampoco es altamente significativo debido a su p-valor. Así que modificamos el modelo eliminando estos coeficiente y ajustamos un SARIMA (1,0,1)x(0,1,1) [12]


Coeficiente	Estimación	Error estándar	Z-valor	p-valor	Significancia
AR(1)	0.7955	0.1088	7.3146	2.58e-13	*** (p<0.001)
MA(1)	-0.5918	0.1435	-4.1250	3.71e-05	*** (p<0.001)
SMA(1)	-0.9229	0.0679	-13.5905	<2.2e-16	*** (p<0.001)

El modelo **SARIMA** estimado tiene la siguiente estructura:


- Orden **no estacional**: (1,0,1) → AR(1), sin diferenciación, MA(1)
- Orden **estacional**: (0,1,1)[12] → Diferenciación estacional de orden 1, con S-MA(1)

Segun el test Box-Jenkins no hay autocorrelación lineal de los residuos que además tiene media igual a 0, entonces **Ruido Blanco**

Residuo





Residuo



Residuos del modelo SARIMA(1,0,1)×(0,1,1)[12]


Residuals from ARIMA(1,0,1)(0,1,1)[12]



En la normal Q-Q Plot observamos que los datos siguen una distribución normal, para una mayor seguridad comprobamos la normalidad mediante el test de Shapiro Wilk. Se tiene que el valor p-valor del test es de $0.15 > 0.05$, por lo que no rechazamos nuestra hipótesis nula, es decir que **los residuos siguen una distribución normal**, el modelo cumple con la independencia, normalidad y los residuos son ruido blanco gaussiano (**GWN**), por lo que el modelo es válido.

Un **gráfico Q-Q normal** es un tipo de gráfico Q-Q en el que un conjunto de datos se compara con una **distribución normal** con parámetros especificados. Se utiliza para evaluar si un conjunto de datos sigue una distribución normal.

Pronostico de la temperatura en Nueva York



	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2020	-0.4467978	-2.6626923	1.769097	-3.835716	2.942120
Feb 2020	0.8933430	-1.3532656	3.139952	-2.542548	4.329234
Mar 2020	5.1507925	2.8738842	7.427701	1.668562	8.633023
Apr 2020	11.4410744	9.1342642	13.747884	7.913113	14.969036
May 2020	17.1912857	14.8549564	19.527615	13.618178	20.764393
Jun 2020	22.1434867	19.7780066	24.508967	18.525797	25.761176
Jul 2020	24.9285163	22.5342403	27.322792	21.266787	28.590246
Aug 2020	24.2181061	21.7953764	26.640836	20.512861	27.923351
Sep 2020	20.3720192	17.9211662	22.822872	16.623763	24.120276
Oct 2020	13.6198482	11.1411909	16.098506	9.829069	17.410628
Nov 2020	7.5911705	5.0850173	10.097324	3.758340	11.424001
Dec 2020	2.3504191	-0.1829640	4.883802	-1.524056	6.224894
Jan 2021	-0.4467978	-3.0070891	2.113493	-4.362425	3.468830
Feb 2021	0.8933430	-1.6935766	3.480263	-3.063009	4.849695
Mar 2021	5.1507925	2.5375160	7.764069	1.154131	9.147454
Apr 2021	11.4410744	8.8017040	14.080445	7.404506	15.477643
May 2021	17.1912857	14.5260769	19.856494	13.115201	21.267371
Jun 2021	22.1434867	19.4526877	24.834286	18.028265	26.258709
Jul 2021	24.9285163	22.2123682	27.644664	20.774526	29.082506
Aug 2021	24.2181061	21.4768432	26.959369	20.025706	28.410506
Sep 2021	20.3720192	17.6058696	23.138169	16.141558	24.602480
Oct 2021	13.6198482	10.8290338	16.410663	9.351666	17.888031
Nov 2021	7.5911705	4.7759073	10.406434	3.285597	11.896744
Dec 2021	2.3504191	-0.4891113	5.189950	-1.992268	6.693106

Metricas de Error


ME RMSE MAE MPE MAPE MASE ACF1

Training set 0.03026281 1.677883 1.331042 Inf Inf 0.709889 0.1006234


El pronóstico se muestra con una **línea azul**, entre los intervalos de predicción del 80% y del 95%, el error promedio en el pronóstico (ME) es de 0.03 y el error absoluto medio del pronóstico (MAE) es de 1.33 esto significa que es un **buen** modelo de predicción. (No perfecto, porque la perfección no existe 😊).

No existen modelos perfectos


Forecasts from ARIMA(1,0,1)(1,1,1)[96]




Forecasts from ARIMA(1,0,1)(1,1,1)[96]




Forecasts from ARIMA(1,0,1)(1,1,1)[96]




Forecasts from ARIMA(1,0,1)(1,1,1)[96]




Forecasts from ARIMA(1,0,1)(1,1,1)[96]



Forecasts from ARIMA(1,0,1)(1,1,1)[96]



Forecasts from ARIMA(1,0,1)(1,1,1)[96]



Forecasts from ARIMA(1,0,1)(1,1,1)[96]

