



Unidad 3

Series Temporales: Modelos SARIMA

Primeros modelos SARIMA para series temporales

ÁREAS DE APLICACIÓN Y CASOS DE USO: ENTORNOS CON
DATOS ESTRUCTURADOS

Modelos de regresión con errores de series temporales

- ✓ Los modelos que hemos estudiado hasta este momento **intentan explicar el futuro de una variable aleatoria basándose en su propio pasado.**
 - ✓ Parece lógico tratar de explicar el futuro de una variable aleatoria junto con el presente y pasado de otras variables explicativas diferentes del pasado de nuestra variable de interés.
 - ✓ La idea es tratar de explicar y predecir con mayor precisión el futuro de nuestra variable de interés.
 - ✓ Existen varias formas de abordar este problema en la literatura estadística.
 - ✓ Vamos a responder a esta cuestión mediante la técnica conocida como "**modelos de regresión con errores de series temporales**".
 - ✓ En muchas aplicaciones reales, la relación entre dos series temporales es de gran interés.
 - ✓ Un ejemplo es la estructura temporal de las tasas de interés, donde se investiga la evolución temporal de la relación entre tasas de interés con diferentes vencimientos.
 - ✓ Este ejemplo lleva al conocido modelo de regresión lineal: $y_t = \alpha + \beta x_t + e_t$
- donde y_t y x_t son dos series temporales y e_t denota el término de error.**
- ✓ Si e_t es un ruido blanco (WN), el método de mínimos cuadrados produce estimaciones consistentes para α y β .
 - ✓ Sin embargo, si e_t está correlacionado en serie, las estimaciones de α y β pueden no ser consistentes.

Consistencia significa que se toma una muestra de la población para estimar un parámetro. Si n aumenta, el parámetro converge al verdadero parámetro de la población. La **consistencia** de un estimador significa que, a medida que aumenta el tamaño de la muestra ($n \rightarrow \infty$), el estimador se acerca al verdadero valor del parámetro de la población. En términos más formales, un estimador $\hat{\theta}_n$ de un parámetro θ es **consistente** si:

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1 \quad \text{para todo } \epsilon > 0.$$

Esto quiere decir que, con suficientes datos, el estimador converge en probabilidad al valor real del parámetro.

Los pasos que debemos seguir al analizar modelos de regresión lineal con errores de series temporales son:



1. Ajustar el modelo de regresión lineal para las variables en la escala original y verificar la correlación serial de los residuos.
2. Si la serie de residuos parece ser estacionaria, identificar un modelo ARMA para los residuos y modificar el modelo de regresión lineal en consecuencia. Si la serie de residuos no es **estacionaria**, **tomar la primera diferencia tanto de la variable dependiente como de las explicativas** y volver al paso 1.
3. Realizar una estimación conjunta mediante el método de máxima verosimilitud y verificar el modelo ajustado para posibles mejoras.
4. Una vez que los residuos del modelo conjunto sean ruido blanco (WN), estamos listos para hacer pronósticos.

Un ejemplo real: relación entre las tasas de intereses semanales de US.

Introducimos el modelo considerando la relación entre dos series semanales de tasas de interés en EE.UU.

- Serie 1: $r_{1,t}$ representa la tasa de madurez constante a 1 año de los bonos del Tesoro.
- Serie 2: $r_{3,t}$ representa la tasa de madurez constante a 3 años de los bonos del Tesoro.

La **correlación** entre estas dos tasas de interes es igual a **0.9823**




PASO 1

Ajustar el modelo de regresión lineal para las variables en la escala original y verificar la correlación serial de los residuos.

El modelo de regresión lineal estimado es:

$$r_{3,t} = 0.832 + 0.93r_{1,t} + e_t$$

donde el coeficiente de determinación R-squared es 96.49% y el error estándar de los residuos es 0.5228. Ahora falta mirar si los residuos son estacionario o necesitan una transformación.



Los residuos son claramente no estacionarios (en terminología econométrica moderna, las dos tasas de interés no están cointegradas y no existe un equilibrio a largo plazo entre ambas tasas de interés).


La prueba DF también sugiere una diferencia regular para los residuos.

PASO 2

Si la serie de residuos **no es estacionaria**, tomar la primera diferencia tanto de la variable dependiente como de las explicativas y volver al paso 1.

Nueva serie 1: $c_{1,t} = (1 - L)r_{1,t}$, cambios en la tasa de interés a 1 año.

Nueva serie 2: $c_{3,t} = (1 - L)r_{3,t}$, cambios en la tasa de interés a 3 años.




La **correlación** ahora es igual a **0.9084**

El modelo de regresión lineal estimado es:


$$c_{3,t} = 0,794c_{1,t} + e_t,$$

donde el coeficiente de determinación R-squared es 85.5% y el error estándar de los residuos es 0.06.

¿Los residuos son ruido blanco (WN) o tienen alguna estructura que se deba considerar?



Vamos a examinarlos más en detalle:



Los residuos **no** son ruido blanco (WN) y un modelo MA(1) puro puede ser bueno para capturar la mayor parte de la estructura presente en los datos.

Nota que los rezagos 4, 6 y 7 son estadísticamente diferentes de cero. Sin embargo, la mejora incremental es pequeña. **¡¡¡PRUEBA ESTO!!!**
 Asumo que el modelo MA(1) es suficiente para nuestros propósitos y continúo el modelado con este modelo simple para los residuos.

Usar un **modelo ARIMA** (o SARIMA si hay estacionalidad) **para los residuos** puede ayudarte a capturar esa dependencia temporal.

Nota que el error no es ruido blanco (WN), entonces eso significa que queda estructura en el error que no está siendo explicada por X_t . Esa estructura puede ser autocorrelación, es decir, que los errores actuales dependen de errores pasados.

Realizar una estimación conjunta mediante el método de máxima verosimilitud y verificar el modelo ajustado para posibles mejoras.

El modelo final para los datos transformados es:

$$c_{3,t} = 0,794 c_{1,t} + e_t$$

$$e_t = a_t + 0,1823 a_{t-1}, \quad \text{con } \sigma_a = 0,0678 \quad \longrightarrow \quad \text{Los residuos del modelo (lo que no se explicó) **tienen correlación temporal.**}$$

Si jugamos con todas las ecuaciones y deshacemos las diferencias regulares, el modelo final expresado en una sola ecuación es el siguiente:

$$r_{3,t} = r_{3,t-1} + 0,794(r_{1,t} - r_{1,t-1}) + a_t + 0,182a_{t-1}$$

La serie de interés puede ser explicada por su propio pasado y por el presente y pasado de otras series.

Esto es un ejemplo de un modelo **ARIMAX** (AutoRegressive Integrated Moving Average with eXogenous variables).

En el modelo: $e_t = a_t + \theta a_{t-1}$

a_t se considera un **ruido blanco** o también llamado **innovación**, que cumple estas características:

- **Media cero:** $\mathbb{E}[a_t] = 0$
- **Varianza constante:** $\text{Var}(a_t) = \sigma_a^2$
- **No hay autocorrelación:** $\text{Cov}(a_t, a_{t-k}) = 0$ para todo $k \neq 0$

Entonces, a_t es lo más puro de lo aleatorio. Es el "ruido base" que genera el comportamiento del error e_t .

¿Por qué no modelamos e_t directamente como ruido blanco?

Porque en muchos casos (como este), el error e_t **sí muestra autocorrelación** es decir, **tiene memoria**. Entonces decimos: "ok, no es puro ruido blanco, pero tal vez si le quitamos una parte que depende del pasado, sí lo sea".

Por eso usamos modelos como MA(1): $e_t = a_t + \theta a_{t-1}$

Aquí el **modelo para los errores** nos permite capturar dependencia en el tiempo, y a_t se convierte en el verdadero "**shock**" aleatorio, limpio, sin estructura.

¿Cómo lo interpretas?

a_t : el verdadero ruido aleatorio (como un shock económico, error de medición, etc.).
 e_t : el error observado, que mezcla ese ruido con influencia del pasado (por eso usamos el MA(1)).