



Unidad 7

Aplicaciones en las Finanzas: Value at Risk y Expected Shortfall

ÁREAS DE APLICACIÓN Y CASOS DE USO: ENTORNOS CON DATOS ESTRUCTURADOS

Risk Management

Las instituciones financieras enfrentan múltiples **categorías de riesgo** que pueden afectar su solvencia, liquidez y rentabilidad. Comprender estas fuentes de incertidumbre es esencial para aplicar modelos de medición y gestión del riesgo adecuados, como el **VaR (Value at Risk)**.

Market Risk (Riesgo de Mercado): Es el riesgo de pérdida debido a movimientos adversos en variables de mercado como tasas de interés, tipos de cambio, precios de acciones o commodities. Es el principal tipo de riesgo que mide el VaR.

Credit Risk (Riesgo de Crédito): Es el riesgo de que una contraparte no cumpla con sus obligaciones contractuales. Se manifiesta, por ejemplo, en impagos de préstamos o en incumplimientos de bonos corporativos.

Riesgo de pérdida por fallos internos en procesos, personas, sistemas o eventos externos (como fraudes, errores humanos, o ciberataques).

Model Risk (Riesgo de Modelo): Es el riesgo de que los modelos utilizados para medir o gestionar los otros riesgos sean incorrectos o estén mal calibrados. Ejemplo: Subestimar el riesgo en un modelo VaR porque no captura adecuadamente la cola de la distribución.

¡Comprender y gestionar estos riesgos es esencial para proteger el capital y asegurar la estabilidad financiera!

Value at Risk

Tras las **recientes crisis financieras** y el incremento en la complejidad de los mercados financieros, **medir el riesgo** se ha convertido en uno de los asuntos más importantes en el sector financiero.



Caida de precios



Bank Run

Desde entonces los supervisores han aumentado los controles de los bancos para **asegurarse de que disponen de suficiente capital para sobrevivir a los mercados deficientes**. Para calcular el capital requerido, se han definido algunas medidas de riesgo.

Estas medidas se suelen utilizar para resumir el riesgo total de una entidad con un único número.

El uso de un único número es beneficioso en muchos aspectos, pero, abre un debate sobre qué medida de riesgo es adecuado utilizar y como se puede comprobar su efectividad.

Durante años la medida más utilizada ha sido **Value-at-Risk (VaR)**. Las razones más importantes para utilizar esta medida son que el concepto es muy fácil de entender y que se puede realizar un backtesting de una manera sencilla.



Disminución en la calidad crediticia

Value at Risk

El VaR se define como un valor límite tal que la probabilidad de que una pérdida de una cartera sobre un horizonte temporal exceda ese valor sea el nivel de probabilidad dado.

O de manera equivalente, con una probabilidad $(1 - \alpha)$ el propietario de esa acción experimentará una pérdida no superior al VaR.

Ejemplo: Inviertes 10.000€ en acciones de la empresa «Florentino grandes obras y puentes, SA». Esta inversión tiene una rentabilidad mensual esperada del 5% con una desviación estándar de 0.10; no se reparten dividendos ni se produce negociación en la cartera durante este período. Para calcular el VaR partimos del supuesto que los retornos tienen una [distribución normal](#) (forma campana de Gauss).

El objetivo es estimar, con una probabilidad determinada, cuándo puedes perder en esta inversión. Por ejemplo: Con una probabilidad de 5% y del 1% ¿Cuál es el valor en riesgo (VaR) mensual para esta inversión?

Esto equivale a calcular el percentil 0.05 y el percentil 0.01, o $q(0.05)$ y $q(0.01)$, de la distribución de los retornos. Es decir, calcular aquel punto del dominio de la función de densidad que deja un 5% y un 1% del área en su rango inferior.

$$\text{VaR} = \text{Inversión inicial} * \text{Percentil}$$

$$5\% \text{ Value at Risk (VaR)} \rightarrow \text{VaR} = q(0.05) * \text{Inversión inicial}$$

	Retornos		Percentiles		Value at Risk (VaR)	
Inversion inicial	μ	σ	$q(0.01)$	$q(0.05)$	1% VaR	5% VaR
\$10.000	0,05	0,10	-0,1826	-0,1145	-\$1.826,35	-\$1.144,85


Interpretación:

5% VaR: con un 5% de probabilidad, la perdida será de 1144,85 o más.

1% VaR: Con un 1% de probabilidad la pérdida sera de de 1826

Value at Risk

Como puedes ver en el gráfico a continuación, la curva representa la distribución de los retornos y el VaR 0.05 equivale a calcular el área del percentil 0.05.




El VaR tiene varios usos relacionados con la gestión del riesgo: Puede utilizarse como medida de control financiero (para no sobrepasar determinados niveles de riesgo); para indicar el riesgo de determinados productos financieros; y como cálculo del capital regulatorio de entidades financieras (según los requerimientos de Basel II).

Value at Risk

El **Value at Risk (VaR)** se ha consolidado como una herramienta clave para cuantificar el riesgo financiero, al estimar la pérdida máxima esperada bajo condiciones normales de mercado, en un horizonte de tiempo definido y con un nivel de confianza determinado. Sin embargo, su efectividad depende críticamente de cómo se modela la **volatilidad**, ya que esta representa el corazón del riesgo de mercado.

Los **Quant Risk Managers** enfrentan el problema de que la volatilidad de los mercados no es constante, sino que exhibe patrones de **persistencia y clustering**: periodos de alta o baja volatilidad tienden a agruparse y prolongarse.

Si se ignora esta característica, por ejemplo utilizando una varianza incondicional que da el mismo peso a todos los datos históricos, se corre el riesgo de **subestimar el riesgo en tiempos turbulentos o sobrestimarlo en tiempos tranquilos**.



El VaR para un nivel de confianza α (por ejemplo, 99%) se calcula como:

$$\text{VaR}_t^\alpha = z_\alpha \cdot \sigma_t$$

Donde z_α es el cuantil de la distribución normal estándar (por ejemplo, $z_{0.99} \approx 2.33$).

Además, la presencia de **colas gordas** en la distribución de los retornos financieros implica que unos pocos eventos extremos pueden distorsionar significativamente las estimaciones basadas en métodos puramente históricos. En consecuencia, una **Función Generadora del Proceso de Volatilidad** que incorpore la **dependencia temporal y condicional** se vuelve esencial para una medición robusta del VaR.

Del VaR Historico a la volatilidad Condicional: EWMA

Una de las primeras soluciones a este problema fue el modelo **EWMA (Exponentially Weighted Moving Average)**, que introdujo la noción de darle mayor importancia a los eventos recientes. El modelo propuesto por **RiskMetrics**, con un parámetro de suavizamiento $\lambda=0.94$, fue una de las primeras implementaciones prácticas de volatilidad condicional. Sin embargo, el EWMA tiene limitaciones al ser un caso especial y restrictivo, sin capacidad de capturar la dinámica más compleja de la volatilidad.

Según el modelo EWMA, la **varianza condicional estimada** para el tiempo t se calcula como:

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) R_{t-1}^2$$

Donde:

- σ_t^2 es la **varianza condicional** estimada para el periodo actual.
- $\lambda \in [0, 1]$ es el **parámetro de suavizamiento** o de "memoria".
- R_{t-1} es el **rendimiento** observado entre $t - 2$ y $t - 1$ (es decir, la "noticia").
- σ_{t-1}^2 es la **varianza estimada** del periodo anterior.

$$\longrightarrow W_t = \underbrace{\beta \cdot W_{t-1}}_{\text{trend}} + \underbrace{(1 - \beta) \cdot \theta_t}_{\text{current value}}$$

✗ Limitaciones de EWMA

No modela explícitamente el comportamiento de los residuos (errores) → **no considera si los choques pasados son positivos o negativos.**

Es un caso particular del modelo **GARCH(1,1)**, con restricciones:

$$\begin{aligned}\omega &= 0 \\ \alpha + \beta &= 1 \\ \alpha &= 1 - \lambda, \beta = \lambda\end{aligned}$$


Es decir, **no permite estimar los parámetros libremente**, lo que lo hace más rígido. Por eso, si bien es un buen primer paso, el modelo **GARCH** es preferido para un análisis más detallado y flexible de la volatilidad.

Del VaR Historico a la volatilidad Condicional: GARCH

Para superar esas limitaciones, surge la familia de modelos **GARCH (Generalized Autoregressive Conditional Heteroskedasticity)**. Estos modelos permiten capturar de manera más precisa la evolución temporal de la volatilidad, al modelar la varianza condicional como una combinación autorregresiva de choques pasados (errores al cuadrado) y varianzas anteriores. En su forma más básica, el modelo **GARCH(1,1)** puede expresarse como:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

95% VaR Forecasting



¿Por qué la combinación VaR-GARCH es más realista?


Cuando la volatilidad del mercado aumenta (por ejemplo, en una crisis financiera), el modelo GARCH lo detecta y **ajusta hacia arriba la estimación de riesgo**, haciendo que el límite de VaR también se ajuste (en este caso, se **reduzca** el umbral de pérdidas permitidas, o se reconozca mayor riesgo).

En contraste, el **VaR estático no responde al cambio en volatilidad**, lo que lleva a frecuentes "**violaciones del límite**": es decir, las pérdidas reales superan el valor que el modelo había predicho como improbable. Esto se refleja en el gráfico como repetidas ocasiones donde la línea roja (VaR estático) es superada.

Ejemplo práctico 1: GARCH(1,1) y VaR

Una estrategia eficaz para resolver este problema es combinar el **VaR con modelos GARCH**, que tienen en cuenta la volatilidad condicional. Para ilustrar este método, aplico un modelo GARCH(1,1) con una distribución normal al índice del mercado de acciones suizo SMI descargado desde **Yahoo Finance**.


^SSMI.Close



1) Evolución histórica del índice bursátil suizo SMI. El gráfico muestra la serie temporal de precios de cierre desde mediados de los años 90 hasta 2015, reflejando las principales crisis y recuperaciones del mercado.

2) Histograma de los rendimientos ajustados del índice SMI. La distribución presenta una forma leptocúrtica con colas más pesadas que la normal, lo que indica la presencia de eventos extremos más frecuentes de lo esperado bajo una distribución normal.

^SSMI.Adj.Close Histogram



Ejemplo práctico 1: GARCH(1,1) y VaR

En los libros de texto, el VaR se define (según el **Delta Normal Approach**) como: $VaR(X) = \mu + \sigma N^{-1}(X)$

Más fácil se puede escribir así: $VaR_t^\alpha = \mu_t + z_\alpha \cdot \sigma_t$

Donde:

μ_t : media de los rendimientos esperados (puede ser 0 en muchos casos para simplificar)

σ_t : volatilidad en el tiempo t (por ejemplo, calculada con GARCH)

z_α : cuantil de la distribución normal estándar para el nivel de confianza α

Para incorporar la volatilidad condicional en el cálculo del VaR, se usa un modelo **GARCH(1,1)**, definido como:

$$\sigma_t^2 = \omega + \alpha R_{t-1}^2 + \beta \sigma_{t-1}^2$$

Los datos de rendimientos del SMI contienen 5,078 observaciones. Utilizo las primeras 3,078 observaciones para realizar la estimación inicial del modelo GARCH. Las 2,000 observaciones restantes se emplean para validación y prueba.

```
# Suponiendo que SMI ya es un DataFrame con una columna de retornos diarios
# Asegúrate de tener la serie cargada como pandas DataFrame: SMI_df

# Volatilidad histórica (desviación estándar móvil de 150 días)
SMI_df['HV'] = SMI_df['returns'].rolling(window=150).std()

# Tomamos solo las últimas 2000 observaciones de la volatilidad histórica
hv = SMI_df['HV'].dropna().iloc[-2000:]

# Separar datos para entrenamiento y prueba
train = SMI_df['returns'].iloc[:3078]
test = SMI_df['returns'].iloc[3078:]

# Modelo GARCH(1,1) sin media (como en include.mean = FALSE)
garch_model = arch_model(train, vol='Garch', p=1, q=1, mean='Zero', dist='normal')

# Ajuste inicial
garch_fit = garch_model.fit(dispen='off')
```

```
# Estimación rolling
rolling_forecasts = []
window_size = 25

for i in range(0, len(test), window_size):
    end = 3078 + i
    window_data = SMI_df['returns'].iloc[end - 3078:end]

    model = arch_model(window_data, vol='Garch', p=1, q=1, mean='Zero', dist='normal')
    res = model.fit(dispen='off')

    # Forecast 1-step ahead
    forecast = res.forecast(horizon=1)
    rolling_forecasts.append(forecast.variance.values[-1, 0])

# Convertir a DataFrame si quieres visualizarlos o unirlos a test
forecast_df = pd.DataFrame({'Forecasted_Volatility': rolling_forecasts})
```


Ejemplo práctico 1: GARCH(1,1) y VaR

Se aplica un modelo **GARCH(1,1)** al índice SMI para capturar la **volatilidad condicional**.

Se entrena con 3078 datos y se valida con 2000 más usando una estrategia de **estimación rodante** (cada 25 días).

Esto permite pronosticar la volatilidad dinámica y utilizarla luego para el cálculo del **Value at Risk (VaR)**.

95% VaR Forecasting



Pronóstico del VaR al 95% para el índice SMI.

La gráfica compara tres enfoques:

- **GARCH(1,1) (línea negra)**: refleja volatilidad condicional y reacciona dinámicamente al riesgo del mercado.
- **Media móvil de 150 días (línea azul)**: estima el VaR usando la volatilidad histórica.
- **VaR estático (línea roja)**: mantiene un umbral fijo basado en la volatilidad promedio, sin adaptarse a cambios.

🔍 Se observa que el modelo GARCH se ajusta mejor a los periodos de alta volatilidad, especialmente durante crisis o caídas bruscas.

Durante episodios de alta volatilidad (como en 2008 y 2011), el modelo GARCH ajusta rápidamente el nivel de VaR, mientras que el VaR basado en media móvil y el VaR estático reaccionan de forma más lenta o no lo hacen en absoluto.

Esto resalta la ventaja del enfoque GARCH para capturar el **agrupamiento de volatilidad** y prevenir la **subestimación del riesgo** en momentos críticos del mercado.

Ejemplo práctico 1: GARCH(1,1) y VaR

En esta sección se comparan diferentes métodos para estimar la **volatilidad de los retornos del índice SMI** a lo largo del tiempo:

1) Volatilidad observada:

Se representa mediante los **retornos absolutos** diarios. Muestra las variaciones reales del mercado, incluyendo los picos de incertidumbre.

2) Volatilidad histórica (MA 150 días):


Calculada como la **desviación estándar móvil** de 150 días. Es una medida simple que suaviza la volatilidad pero responde con lentitud a cambios bruscos.

3) Volatilidad incondicional:

Es una medida constante basada en la **desviación estándar total de los datos**. No cambia en el tiempo y no refleja las condiciones actuales del mercado.

4) Volatilidad condicional (GARCH(1,1)):

Estimada usando un modelo GARCH aplicado de forma **rolling**. Se ajusta dinámicamente al comportamiento reciente del mercado, capturando mejor episodios de alta volatilidad.



El modelo GARCH(1,1) ofrece una estimación más realista y adaptable de la volatilidad, especialmente útil en contextos de riesgo como el cálculo del VaR. Supera claramente a las medidas históricas y constantes en momentos de crisis o alta incertidumbre.

Ejemplo práctico 2: GARCH(1,1) y VaR


El propósito de este análisis es construir un proceso que permita estimar adecuadamente el **Valor en Riesgo (VaR)** teniendo en cuenta la **volatilidad que varía en el tiempo**. El VaR es una medida ampliamente utilizada por las instituciones financieras para evaluar el **riesgo de mercado**.

Para ello, se utilizan **rendimientos diarios de acciones durante un período de 1,258 días**. Con el objetivo de explicar una pequeña proporción de la varianza de los retornos diarios, se aplica la **metodología Box-Jenkins**, ajustando un modelo **ARIMA (Autorregresivo Integrado de Media Móvil)**. Se evalúan los supuestos subyacentes del modelo y se examina la **normalidad de los retornos**, considerando posibles alternativas más adecuadas en términos de distribución.

Posteriormente, se estima la **varianza condicional de los residuos** mediante un modelo **GARCH (Heterocedasticidad Condicional Autorregresiva Generalizada)** y se compara con el enfoque tradicional de **VaR delta-normal**, que asume volatilidad constante y distribución normal de los rendimientos.

Finalmente, se realiza un **pronóstico del VaR a un paso (1-step ahead)** y se lleva a cabo un **backtesting** para validar si el modelo es adecuado y confiable para capturar correctamente el riesgo de pérdidas extremas.

Para el proceso de modelado, se **recopilaron 5 años de datos (febrero de 2013 a febrero de 2018)** de las acciones de **Citigroup Inc.**, con una frecuencia diaria, lo que resulta en un total de **1,259 observaciones**.



Ejemplo práctico 2: GARCH(1,1) y VaR

La **línea roja** representa el **precio de cierre promedio** durante este periodo de tiempo.

Los procesos no estacionarios tienen medias, varianzas y covarianzas que cambian con el tiempo. Usar series temporales no estacionarias puede llevar a **pronósticos poco confiables**. Un proceso estacionario, en cambio, es **revertido a la media**, es decir, fluctúa en torno a una media constante con varianza constante. En este análisis, nos referimos a **estacionariedad débil**, la cual cumple tres condiciones:


- $E(y_t) = \mu$
- $E(y_t^2) = \sigma^2 < \infty$
- $Cov(y_1, y_{1+s}) = Cov(y_2, y_{2+s}) = \dots = Cov(y_T, y_{T+s}) = \gamma_s$

Para resolver este problema, se suele aplicar la técnica de **diferenciación**. La diferencia de primer orden se expresa como:

$$\Delta y_t = y_t - y_{t-1}$$

En nuestro caso, para lograr la transformación a estacionariedad, preferimos calcular los **rendimientos diarios simples**, definidos como:

$$r_t = \frac{price_t - price_{t-1}}{price_{t-1}}$$



```
adf.test(rets)
```

```
##
## Augmented Dickey-Fuller Test
##
## data:  rets
## Dickey-Fuller = -10.635, Lag order = 10, p-value = 0.01
## alternative hypothesis: stationary
```

Los retornos según el ADF es estacionaria

Ejemplo práctico 2: GARCH(1,1) y VaR

`k = number of model parameters (p + q + 1)`



It is obvious that when extra lag parameters are added to the model Sum Squared of Residuals decreases but overfitting problems may occur. AIC deals with both the risk of overfitting and underfitting. The model with the lowest AIC will be selected.

```
model.arima = auto.arima(rets , max.order = c(3 , 0 ,3) , stationary = TRUE , trace = T , ic = 'aicc')
```

```
##
## Fitting models using approximations to speed things up...
##
## ARIMA(2,0,2) with non-zero mean : -6989.225
## ARIMA(0,0,0) with non-zero mean : -6988.069
## ARIMA(1,0,0) with non-zero mean : -6987.582
## ARIMA(0,0,1) with non-zero mean : -6988.352
## ARIMA(0,0,0) with zero mean : -6988.321
## ARIMA(1,0,2) with non-zero mean : -6987.716
## ARIMA(2,0,1) with non-zero mean : -6991.239
## ARIMA(1,0,1) with non-zero mean : -6986.887
## ARIMA(2,0,0) with non-zero mean : -6991.643
## ARIMA(3,0,0) with non-zero mean : -6989.479
## ARIMA(3,0,1) with non-zero mean : -6988.184
## ARIMA(2,0,0) with zero mean : -6992.036
## ARIMA(1,0,0) with zero mean : -6988.026
## ARIMA(3,0,0) with zero mean : -6989.908
## ARIMA(2,0,1) with zero mean : -6991.693
## ARIMA(1,0,1) with zero mean : -6987.233
## ARIMA(3,0,1) with zero mean : -6988.554
##
## Now re-fitting the best model(s) without approximations...
##
## ARIMA(2,0,0) with zero mean : -6990.171
##
## Best model: ARIMA(2,0,0) with zero mean
```


One can observe with the process above we computed AIC scores for various ARIMA models and we infer that the appropriate model is a **2-order Autoregressive (AR(2))**.

Se ha detectado un modelo AR(2) para la media y estos son los residuos (Son Ruido Blanco) según el test Box-Test



Ejemplo práctico 2: GARCH(1,1) y VaR

Squared Residuals



Mirando los residuos al cuadrado, notamos que hay correlación: hace falta un modelo GARCH/ARCH. Vamos a implementar un modelo GARCH(1,1)

```
##           Estimate      Std. Error    t value   Pr(>|t|)
## mu      0.00094048920  0.000369610860    2.544539  0.01094221
## omega   0.00001530555  0.000001754348    8.724350  0.00000000
## alpha1  0.10866225496  0.012769730765    8.509361  0.00000000
## beta1   0.82466334606  0.016771359876   49.170929  0.00000000
```

📌 ¿Qué es μ en esta estimación?



μ es el término de media del modelo. Es decir:

$$y_t = \mu + \varepsilon_t$$


donde:

- y_t son los rendimientos (o los residuos del modelo ARIMA, si ya aplicaste uno),
- μ es la **media constante** del proceso de retornos,
- ε_t es el componente de ruido (innovación) con varianza condicional σ_t^2 , modelada por el GARCH.

¿Quien sabe decirme como es la formula del GARCH(1,1)?



Ejemplo práctico 2: VaR y Backtesting



Red line denotes VaR produced by GARCH model and green line refers to delta-normal VaR.



¿Por qué es importante?

El backtesting permite verificar si el modelo de VaR es **confiable**. Si hay **demasiadas o muy pocas excepciones**, el modelo está subestimando o sobreestimando el riesgo.

Un buen modelo debe generar un número de excepciones consistente con el nivel de confianza elegido.

Aquí hay una comparación entre el VaR producido a partir de un GARCH(1,1) (**línea roja**) y el VaR producido a partir del «Delta-Normal Approach» cuyos supuestos son que los retornos de los activos siguen una distribución normal y que la volatilidad es constante a lo largo del tiempo.

¿Qué es el Backtesting del VaR?

Backtesting es una técnica utilizada para **validar la precisión de un modelo de riesgo**, como el **Valor en Riesgo (VaR)**. Consiste en comparar las **predicciones del modelo** con lo que realmente ocurrió en el pasado. En el contexto del VaR, **evaluamos cuántas veces las pérdidas reales superan el nivel de riesgo estimado** por el modelo. A estos casos se les llama **excepciones o violaciones del VaR**.


Matemáticamente, si:

- $I_t = 1$ cuando la pérdida en el día t supera el VaR estimado, y
- $I_t = 0$ en caso contrario,

Entonces, el **número total de excepciones** es:

$$N = \sum_{t=1}^T I_t$$

Ejemplo práctico 2: VaR y Backtesting



Este gráfico muestra la **distribución teórica de probabilidades** del número de excepciones (violaciones del VaR) bajo una distribución binomial $B(500, 0.05)$, es decir:


- 500 observaciones (días del test set),
- 5% de probabilidad de que ocurra una excepción cada día (VaR al 95%).

La **curva negra** representa la probabilidad de observar un cierto número de excepciones si el modelo de VaR fuera perfectamente calibrado. Las **líneas rojas** indican los límites del intervalo de confianza del 95%:

- Inferior: **16 excepciones**
- Superior: **35 excepciones**

Esto significa que, si el número real de excepciones observadas cae **dentro de este rango (16–35)**, el modelo GARCH se considera **estadísticamente válido y adecuado para predecir el riesgo**.

Ejemplo práctico 2: VaR y conclusiones



Este gráfico muestra el resultado del **backtesting del VaR** estimado con el modelo **GARCH(1,1)** sobre el conjunto de prueba (500 observaciones).

Línea negra: representa el **VaR diario pronosticado** al 95% de confianza por el modelo GARCH.

Puntos grises: representan los **retornos reales diarios**.

Puntos rojos: marcan los días donde los retornos reales **fueron más bajos que el VaR**, es decir, **excepciones**(violaciones del VaR).

El modelo GARCH predice correctamente el nivel de pérdidas extremas la mayor parte del tiempo, con pocas excepciones fuera del VaR. Esto refuerza su utilidad como herramienta de medición del riesgo.

Ejemplo práctico 2: Expected Shortfall

El **Expected Shortfall** (también conocido como **Conditional VaR** o **CVaR**) es una medida de riesgo que **mejora** al **VaR (Value at Risk)** porque **sí tiene en cuenta la magnitud** de las pérdidas extremas. Es decir:

Mientras que el **VaR** te dice:

"En el peor 5% de los casos perderás al menos X",

el **Expected Shortfall** te dice:

"En promedio, si estás en ese 5% peor, perderás Y".

El Expected Shortfall al nivel α de una variable aleatoria X se define como:

$$ES_{\alpha}(X) = \frac{1}{\alpha} \int_0^{\alpha} q_u(X) du$$

donde:


- $q_u(X)$ es el cuantil de orden u de la distribución de X ,
- Es decir, promedia **todos los valores extremos por debajo del VaR**, ponderados por su probabilidad.

✓ Interpretación práctica:

- Si $\alpha = 0.05$, el ES calcula el **promedio de las peores pérdidas del 5% de los casos**.
- Si la distribución es **continua**, se puede escribir también como:

$$ES_{\alpha}(X) = \mathbb{E}[X \mid X \leq q_{\alpha}(X)]$$

Es decir: el valor esperado de las pérdidas, dado que estas están por debajo del VaR.



El Expected Shortfall es una **medida más completa del riesgo extremo** que el VaR. No solo te dice cuál es el umbral mínimo de pérdida en un escenario extremo, sino también cuál es la **pérdida promedio esperada** si llegas a estar en ese escenario. Además, el VaR no da información sobre la gravedad de las pérdidas, no tiene en cuenta como son las pérdidas que exceden ese umbral VaR, al contrario que el ES. **Dos carteras con el mismo VaR pueden tener distinto ES**